

线性回归模型

数据科学与大数据技术专业

第 2 讲

1 概率论基础回顾

1. 概率空间与随机变量

- 概率空间记为 $(\Omega, \mathcal{F}, P)$, 用于刻画随机试验及其不确定性.
 - 样本空间 Ω : 随机试验所有可能结果的集合.
 - 样本点 ω : Ω 中的一个基本结果.
 - 事件 A : 样本空间的子集.
 - 事件域 $\mathcal{F}$: 定义在 Ω 上的 σ -代数.
 - 概率测度 P : 满足非负性、规范性和可列可加性的函数.
- 随机变量是定义在概率空间上的可测函数, 常用来将随机结果映射为数值.
- 随机变量的分布通常通过以下对象描述:
 - 分布函数 (CDF): $F(x) = P(X \leq x)$.
 - 概率质量函数 (PMF): 用于离散型随机变量, 给出 $P(X = x)$.
 - 概率密度函数 (PDF): 用于连续型随机变量, 满足 $P(a \leq X \leq b) = \int_a^b f(x) dx$.
- 按取值形式, 随机变量可分为离散型和连续型; 前者常见于计数问题, 后者常见于测量问题.

2. 随机向量与分布关系

- 随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 用于同时描述多个随机变量.
- 联合分布刻画多个随机变量同时取值的概率规律; 对连续型随机向量, 可进一步用联合密度函数描述.
- 边际分布可由联合分布对其余变量求和或积分得到, 因而只反映单个变量的统计规律.
- 条件概率刻画在已知部分信息时其余事件发生的可能性, 贝叶斯公式为

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}.$$

- 若 X 与 Y 的联合分布等于各自边际分布的乘积, 则称它们相互独立.

3. 采样、期望与大数定律

- 常见采样方法包括:
 - 直接采样: 从已知分布直接生成样本.

- 逆变换采样: 先生成均匀随机变量, 再利用分布函数的反函数得到目标分布样本.
- 期望反映随机变量在重复试验下的平均水平, 是许多学习准则和统计量的基础.
- 大数定律说明: 当样本量充分大时, 样本均值会以概率收敛的方式逼近期望, 这为用样本统计量近似总体统计量提供了理论依据.

问题思考:

- 什么是概率空间? 请举例说明.
- 已知一个二维随机向量的边缘分布, 能否知道它的联合分布?
- 如何理解大数定律在实际中的意义?

2 线性回归概述

1. 模型表示

- 线性回归假设输出是输入特征的线性函数. 若将偏置项并入增广特征向量, 则模型可写为

$$\hat{y} = f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^\top \mathbf{x}.$$

- 其中 $\mathbf{x} \in \mathbb{R}^M$ 表示样本特征, $\mathbf{w} \in \mathbb{R}^M$ 表示待学习参数.
- 该模型主要用于连续值预测任务, 如房价预测、销量预测和温度估计等.

2. 基本特点

- 模型形式简单、参数含义清晰, 便于分析和解释.
- 在线性假设成立或经过特征变换后近似成立时, 线性回归往往能够给出有效基线.

3 参数估计方法

1. 经验风险最小化

- 在线性回归中, 常用平方损失作为学习准则. 对于训练集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 经验风险可写为

$$\begin{aligned} \mathcal{R}(\mathbf{w}) &= \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \mathbf{w})) \\ &= \frac{1}{2} \sum_{n=1}^N (y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2. \end{aligned}$$

- 若将全部样本按列堆叠成矩阵

$$\mathbf{X} = [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}] \in \mathbb{R}^{M \times N}, \quad \mathbf{y} = [y^{(1)}, y^{(2)}, \dots, y^{(N)}]^\top \in \mathbb{R}^N,$$

则预测向量满足

$$\hat{\mathbf{y}} = \mathbf{X}^\top \mathbf{w}.$$

- 因而经验风险可进一步写成紧凑的矩阵形式

$$\mathcal{R}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2.$$

- 解析解的推导要点:

- 对目标函数求梯度可得

$$\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} = -\mathbf{X} (\mathbf{y} - \mathbf{X}^\top \mathbf{w}) = \mathbf{X} \mathbf{X}^\top \mathbf{w} - \mathbf{X} \mathbf{y}.$$

- 令梯度为零, 可得正规方程

$$\mathbf{X} \mathbf{X}^\top \mathbf{w} = \mathbf{X} \mathbf{y}.$$

- 当 $\mathbf{X} \mathbf{X}^\top$ 可逆时, 经验风险最小化的解析解为

$$\mathbf{w}^* = (\mathbf{X} \mathbf{X}^\top)^{-1} \mathbf{X} \mathbf{y}.$$

- 上式说明: 在线性回归中, 最小二乘解本质上就是平方损失下的经验风险最小化解.

2. 结构风险最小化

- 当特征存在共线性、样本不足或噪声较大时, 矩阵 $\mathbf{X} \mathbf{X}^\top$ 可能不可逆或病态, 从而使经验风险最小化的解析解不稳定.
- 一个自然的改进方式是在经验风险中加入参数范数惩罚项, 即采用结构风险最小化:

$$\mathcal{R}_{\text{strm}}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

其中 $\lambda > 0$ 为正则化系数.

- 加入 $\lambda \|\mathbf{w}\|^2$ 的主要作用:

- 在数值计算上, 需要求逆的矩阵变为 $\mathbf{X} \mathbf{X}^\top + \lambda \mathbf{I}$, 可显著改善可逆性和稳定性.
- 在统计学习上, 它通过限制参数幅度来控制模型复杂度, 从而缓解过拟合.

- 相应的最优解为

$$\mathbf{w}^* = (\mathbf{X} \mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{X} \mathbf{y}.$$

问题思考:

- 为什么线性回归模型需要引入正则化?
- 线性回归的概率解释与最小二乘法有何联系?

4 概率视角解释

从概率建模的角度看, 线性回归不仅是在拟合一个函数, 也可以理解为在学习条件分布 $p(y | \mathbf{x}; \mathbf{w})$. 在这一视角下, 最小二乘法、最大似然估计和带正则化的参数估计之间具有统一的解释.

1. 函数建模与条件概率建模

- 函数建模关注的是寻找映射关系 $f(\mathbf{x}; \mathbf{w})$, 并通过最小化损失函数来学习参数.

- 条件概率建模则假设数据由某个概率过程生成, 目标是估计给定输入时输出的条件分布.
- 对线性回归而言, 这两种视角在高斯噪声假设下会导向一致的参数估计结果.

2. 高斯噪声假设与似然函数

- 假设在给定输入 $\mathbf{x}$ 和参数 $\mathbf{w}$ 时, 输出满足

$$y \mid \mathbf{x}, \mathbf{w} \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2).$$

- 这里的“概率”强调在参数已知时观测数据出现的可能性; “似然”则是把观测数据固定后, 将其看作参数 $\mathbf{w}$ 的函数.
- 对于独立同分布样本, 似然函数为

$$L(\mathbf{w}) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2}{2\sigma^2}\right)$$

3. 最大似然估计 (MLE)

- 最大似然估计的目标是寻找使对数似然最大的参数 $\mathbf{w}_{MLE}^*$.
- 去掉与参数无关的常数项后, 负对数似然为

$$-\ln L(\mathbf{w}) \propto \frac{1}{2\sigma^2} \sum_{n=1}^N (y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2$$

这表明: 当噪声服从高斯分布时, 最大化似然等价于最小化平方误差, 因而与经验风险最小化共享同一个最优解.

$$\mathbf{w}_{MLE}^* = \arg \max_{\mathbf{w}} \ln L(\mathbf{w}) = (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{X}\mathbf{y}$$

4. 贝叶斯估计

- 贝叶斯方法不再把参数 $\mathbf{w}$ 视为固定常数, 而是将其视为随机变量, 进而学习后验分布 $p(\mathbf{w} \mid \mathbf{X}, \mathbf{y})$.
- 若先验取为零均值高斯分布

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \nu^2 \mathbf{I}),$$

则后验对数在省略常数项后满足

$$\begin{aligned} \log p(\mathbf{w} \mid \mathbf{X}, \mathbf{y}; \nu, \sigma) &\propto \log p(\mathbf{y} \mid \mathbf{X}, \mathbf{w}; \sigma) + \log p(\mathbf{w}; \nu) \\ &\propto -\frac{1}{2\sigma^2} \sum_{n=1}^N (y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w} \\ &= -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w}. \end{aligned}$$

- 后验分布综合了数据提供的信息和参数先验的信息, 因而不仅给出参数点估计, 也刻画了参数不确定性.

- 对于新样本 $\mathbf{x}^*$, 贝叶斯预测需要对参数后验做积分:

$$p(y^* | \mathbf{x}^*, \mathbf{X}, \mathbf{y}) = \int p(y^* | \mathbf{x}^*, \mathbf{w}) p(\mathbf{w} | \mathbf{X}, \mathbf{y}) d\mathbf{w}.$$

5. 最大后验估计 (MAP) 与正则化

- 严格的贝叶斯预测需要处理整个后验分布, 计算量往往较大. 在实践中, 常采用后验分布的众数作为点估计, 即最大后验估计.
- 最大化后验概率等价于最小化负对数后验, 因而等价于最小化“平方误差项 + 参数范数项”

- 若记

$$\lambda = \frac{\sigma^2}{\nu^2},$$

则 MAP 与带 L_2 正则项的结构风险最小化完全一致, 对应解析解为

$$\mathbf{w}_{MAP}^* = \arg \max_{\mathbf{w}} \log p(\mathbf{w} | \mathbf{X}, \mathbf{y}) = (\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{X}\mathbf{y}$$

6. 估计思想总结

- 线性回归中几种常见估计思想之间的关系可概括如下:

	无先验信息 (唯数据论)	加入先验信息
函数测度视角 (平方误差)	经验风险最小化 (ERM)	结构风险最小化 (SRM)
概率分布视角 (概率统计)	最大似然估计 (MLE)	最大后验估计 (MAP)
最优参数的闭式解:		
$\mathbf{w}_{MLE/ERM}^*$	$(\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{X}\mathbf{y}$	
$\mathbf{w}_{MAP/SRM}^*$	$(\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{X}\mathbf{y}$	

(注: 详细定义和更多的内容请参考课程教材第二章、附录 D.)