

线性回归模型

数据科学与大数据技术专业

第 2 讲

1 导读

除本导读外, 本讲共有 4 个主体节. 它们从概率语言开始, 逐步建立线性回归模型, 推导参数估计方法, 再用概率视角解释为什么平方损失和正则化会自然出现.

1. **概率论基础回顾:** 回顾概率空间、随机变量、联合分布、条件概率、采样、期望和大数定律, 为后续概率建模打基础.
2. **线性回归概述:** 说明线性回归如何用特征的线性组合预测连续值, 以及它为什么是重要的基线模型.
3. **参数估计方法:** 说明如何通过平方损失最小化学习参数, 以及正则化如何改善病态问题和过拟合.
4. **概率视角解释:** 说明高斯噪声、最大似然估计、最大后验估计与线性回归正则化之间的关系.

如果细节都忘了: 最应该记住的是, 线性回归既可以看作最小化平方误差的函数拟合问题, 也可以看作高斯噪声假设下的概率估计问题; 加入 L_2 正则化, 就相当于给参数加入“不要太大”的先验偏好.

问题思考:

- 为什么同一个线性回归公式, 可以同时从几何误差和概率生成两个角度理解?

2 概率论基础回顾

本节导读:

- **本节目的:** 回顾描述随机性所需的基本概念, 为后面用概率解释模型和损失函数做准备.
- **为什么学:** 机器学习中的数据、噪声、采样误差和泛化能力都离不开概率语言, 不先统一记号会影响后续推导.
- **核心内容:** 概率空间定义随机试验, 随机变量把结果映射为数值, 分布、条件概率、期望和大数定律则描述随机变量的规律.
- **最小例子:** 掷一枚骰子时, 样本空间是 $\{1, \dots, 6\}$, 随机变量可以取点数本身, 期望表示长期平均点数, 大数定律说明样本平均会逐渐接近期望.
- **最该记住:** 概率论给机器学习提供了处理不确定性和用样本近似总体的语言.

1. 概率空间与随机变量

- 概率空间记为 $(\Omega, \mathcal{F}, P)$, 用于刻画随机试验及其不确定性.
 - 样本空间 Ω : 随机试验所有可能结果的集合.
 - 样本点 ω : Ω 中的一个基本结果.
 - 事件 A : 样本空间的子集.
 - 事件域 $\mathcal{F}$: 定义在 Ω 上的 σ -代数.
 - 概率测度 P : 满足非负性、规范性和可列可加性的函数.
- 随机变量是定义在概率空间上的可测函数, 常用来将随机结果映射为数值.
- 随机变量的分布通常通过以下对象描述:
 - 分布函数 (CDF): $F(x) = P(X \leq x)$.
 - 概率质量函数 (PMF): 用于离散型随机变量, 给出 $P(X = x)$.
 - 概率密度函数 (PDF): 用于连续型随机变量, 满足 $P(a \leq X \leq b) = \int_a^b f(x) dx$.
- 按取值形式, 随机变量可分为离散型和连续型; 前者常见于计数问题, 后者常见于测量问题.

2. 随机向量与分布关系

- 随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 用于同时描述多个随机变量.
- 联合分布刻画多个随机变量同时取值的概率规律; 对连续型随机向量, 可进一步用联合密度函数描述.
- 边际分布可由联合分布对其余变量求和或积分得到, 因而只反映单个变量的统计规律.
- 条件概率刻画在已知部分信息时其余事件发生的可能性, 贝叶斯公式为

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}.$$

- 若 X 与 Y 的联合分布等于各自边际分布的乘积, 则称它们相互独立.

3. 采样、期望与大数定律

- 常见采样方法包括:
 - 直接采样: 从已知分布直接生成样本.
 - 逆变换采样: 先生成均匀随机变量, 再利用分布函数的反函数得到目标分布样本.
- 期望反映随机变量在重复试验下的平均水平, 是许多学习准则和统计量的基础.
- 大数定律说明: 当样本量充分大时, 样本均值会以概率收敛的方式逼近期望, 这为用样本统计量近似总体统计量提供了理论依据.

问题思考:

- 什么是概率空间? 请举例说明.
- 已知一个二维随机向量的边缘分布, 能否知道它的联合分布?
- 如何理解大数定律在实际中的意义?

3 线性回归概述

本节导读:

- **本节目的:** 引入线性回归模型, 说明如何用特征的线性组合预测连续输出.
- **为什么学:** 线性回归形式简单、可解释、可推导, 是理解更复杂监督学习模型的基础参照.
- **核心内容:** 模型假设 $\hat{y} = \mathbf{w}^\top \mathbf{x}$, 参数 $\mathbf{w}$ 决定各特征对预测值的贡献.
- **最小例子:** 若只用房屋面积预测房价, 可以写成 $\hat{y} = w_0 + w_1 x$, 其中 w_1 表示面积每增加一个单位时预测价格的变化量.
- **最该记住:** 线性回归的强处在于简单清晰, 局限在于它默认输出与特征之间主要满足线性关系.

1. 模型表示

- 线性回归假设输出是输入特征的线性函数. 若将偏置项并入增广特征向量, 则模型可写为

$$\hat{y} = f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^\top \mathbf{x}.$$

- 其中 $\mathbf{x} \in \mathbb{R}^M$ 表示样本特征, $\mathbf{w} \in \mathbb{R}^M$ 表示待学习参数.
- 该模型主要用于连续值预测任务, 如房价预测、销量预测和温度估计等.

2. 基本特点

- 模型形式简单、参数含义清晰, 便于分析和解释.
- 在线性假设成立或经过特征变换后近似成立时, 线性回归往往能够给出有效基线.

问题思考:

- 线性回归为什么适合作为连续值预测任务的基线模型?
- 若真实关系明显非线性, 可以通过哪些方式扩展线性回归的表达能力?

4 参数估计方法

本节导读:

- **本节目的:** 推导如何从训练数据中估计线性回归参数, 并说明正则化为什么能让解更稳定.
- **为什么学:** 模型形式只规定了可选函数, 参数估计才决定最终使用哪一个函数做预测.
- **核心内容:** 平方损失下的经验风险最小化可导出正规方程; 当矩阵病态或模型容易过拟合时, 可加入 L_2 正则项得到岭回归形式.
- **最小例子:** 若两个输入特征几乎完全相同, 最小二乘解可能在两列之间任意分配很大的正负权重; 加入 $\lambda \|\mathbf{w}\|^2$ 后, 解会更倾向于较小且稳定的参数.
- **最该记住:** 参数估计就是选择让训练误差小且足够稳定的 $\mathbf{w}$, 正则化是在“拟合数据”和“控制参数规模”之间做折中.

1. 经验风险最小化

- 在线性回归中, 常用平方损失作为学习准则. 对于训练集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 经验风险可写为

$$\begin{aligned}\mathcal{R}(\mathbf{w}) &= \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \mathbf{w})) \\ &= \frac{1}{2} \sum_{n=1}^N (y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2.\end{aligned}$$

- 若将全部样本按列堆叠成矩阵

$$\mathbf{X} = [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}] \in \mathbb{R}^{M \times N}, \quad \mathbf{y} = [y^{(1)}, y^{(2)}, \dots, y^{(N)}]^\top \in \mathbb{R}^N,$$

则预测向量满足

$$\hat{\mathbf{y}} = \mathbf{X}^\top \mathbf{w}.$$

- 因而经验风险可进一步写成紧凑的矩阵形式

$$\mathcal{R}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2.$$

- 解析解的推导要点:

- 对目标函数求梯度可得

$$\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} = -\mathbf{X}(\mathbf{y} - \mathbf{X}^\top \mathbf{w}) = \mathbf{X}\mathbf{X}^\top \mathbf{w} - \mathbf{X}\mathbf{y}.$$

- 令梯度为零, 可得正规方程

$$\mathbf{X}\mathbf{X}^\top \mathbf{w} = \mathbf{X}\mathbf{y}.$$

- 当 $\mathbf{X}\mathbf{X}^\top$ 可逆时, 经验风险最小化的解析解为

$$\mathbf{w}^* = (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{X}\mathbf{y}.$$

- 上式说明: 在线性回归中, 最小二乘解本质上就是平方损失下的经验风险最小化解.

2. 结构风险最小化

- 当特征存在共线性、样本不足或噪声较大时, 矩阵 $\mathbf{X}\mathbf{X}^\top$ 可能不可逆或病态, 从而使经验风险最小化的解析解不稳定.
- 一个自然的改进方式是在经验风险中加入参数范数惩罚项, 即采用结构风险最小化:

$$\mathcal{R}_{\text{srn}}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

其中 $\lambda > 0$ 为正则化系数.

- 加入 $\lambda \|\mathbf{w}\|^2$ 的主要作用:

- 在数值计算上, 需要求逆的矩阵变为 $\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I}$, 可显著改善可逆性和稳定性.
- 在统计学习上, 它通过限制参数幅度来控制模型复杂度, 从而缓解过拟合.

- 相应的最优解为

$$\mathbf{w}^* = (\mathbf{X}\mathbf{X}^\top + \lambda\mathbf{I})^{-1} \mathbf{X}\mathbf{y}.$$

问题思考:

- 为什么线性回归模型需要引入正则化?
- 线性回归的概率解释与最小二乘法有何联系?

5 概率视角解释

本节导读:

- **本节目的:** 从概率生成过程解释线性回归, 把平方损失、最大似然和正则化联系起来.
- **为什么学:** 同一个训练目标若能从概率角度解释, 就能更清楚地理解噪声假设、参数先验和不确定性.
- **核心内容:** 高斯噪声假设下最大似然等价于最小二乘, 高斯先验下最大后验等价于带 L_2 正则的线性回归.
- **最小例子:** 若温度计读数等于真实线性趋势加上高斯测量误差, 那么让所有残差平方和最小, 就是在寻找最可能生成这些读数的线性模型.
- **最该记住:** 平方损失不是凭空选择的, 它对应高斯噪声; L_2 正则也不是纯技巧, 它对应参数服从零均值高斯先验.

从概率建模的角度看, 线性回归不仅是在拟合一个函数, 也可以理解为在学习条件分布 $p(y \mid \mathbf{x}; \mathbf{w})$. 在这一视角下, 最小二乘法、最大似然估计和带正则化的参数估计之间具有统一的解释.

1. 函数建模与条件概率建模

- 函数建模关注的是寻找映射关系 $f(\mathbf{x}; \mathbf{w})$, 并通过最小化损失函数来学习参数.
- 条件概率建模则假设数据由某个概率过程生成, 目标是估计给定输入时输出的条件分布.
- 对线性回归而言, 这两种视角在高斯噪声假设下会导向一致的参数估计结果.

2. 高斯噪声假设与似然函数

- 假设在给定输入 $\mathbf{x}$ 和参数 $\mathbf{w}$ 时, 输出满足

$$y \mid \mathbf{x}, \mathbf{w} \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2).$$

- 这里的“概率”强调在参数已知时观测数据出现的可能性; “似然”则是把观测数据固定后, 将其看作参数 $\mathbf{w}$ 的函数.
- 对于独立同分布样本, 似然函数为

$$L(\mathbf{w}) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2}{2\sigma^2}\right)$$

3. 最大似然估计 (MLE)

- 最大似然估计的目标是寻找使对数似然最大的参数 $\mathbf{w}_{MLE}^*$.
- 去掉与参数无关的常数项后, 负对数似然为

$$-\ln L(\mathbf{w}) \propto \frac{1}{2\sigma^2} \sum_{n=1}^N (y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2$$

这表明: 当噪声服从高斯分布时, 最大化似然等价于最小化平方误差, 因而与经验风险最小化共享同一个最优解.

$$\mathbf{w}_{MLE}^* = \arg \max_{\mathbf{w}} \ln L(\mathbf{w}) = (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{X}\mathbf{y}$$

4. 贝叶斯估计

- 贝叶斯方法不再把参数 $\mathbf{w}$ 视为固定常数, 而是将其视为随机变量, 进而学习后验分布 $p(\mathbf{w} | \mathbf{X}, \mathbf{y})$.
- 若先验取为零均值高斯分布

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \nu^2 \mathbf{I}),$$

则后验对数在省略常数项后满足

$$\begin{aligned} \log p(\mathbf{w} | \mathbf{X}, \mathbf{y}; \nu, \sigma) &\propto \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}; \sigma) + \log p(\mathbf{w}; \nu) \\ &\propto -\frac{1}{2\sigma^2} \sum_{n=1}^N (y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)})^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w} \\ &= -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w}. \end{aligned}$$

- 后验分布综合了数据提供的信息和参数先验的信息, 因而不仅给出参数点估计, 也刻画了参数不确定性.
- 对于新样本 $\mathbf{x}^*$, 贝叶斯预测需要对参数后验做积分:

$$p(y^* | \mathbf{x}^*, \mathbf{X}, \mathbf{y}) = \int p(y^* | \mathbf{x}^*, \mathbf{w}) p(\mathbf{w} | \mathbf{X}, \mathbf{y}) d\mathbf{w}.$$

5. 最大后验估计 (MAP) 与正则化

- 严格的贝叶斯预测需要处理整个后验分布, 计算量往往较大. 在实践中, 常采用后验分布的众数作为点估计, 即最大后验估计.
- 最大化后验概率等价于最小化负对数后验, 因而等价于最小化“平方误差项 + 参数范数项”.
- 若记

$$\lambda = \frac{\sigma^2}{\nu^2},$$

则 MAP 与带 L_2 正则项的结构风险最小化完全一致, 对应解析解为

$$\mathbf{w}_{MAP}^* = \arg \max_{\mathbf{w}} \log p(\mathbf{w} | \mathbf{X}, \mathbf{y}) = (\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{X}\mathbf{y}$$

6. 估计思想总结

- 线性回归中几种常见估计思想之间的关系可概括如下:

	无先验信息 (唯数据论)	加入先验信息
函数测度视角 (平方误差)	经验风险最小化 (ERM)	结构风险最小化 (SRM)
概率分布视角 (概率统计)	最大似然估计 (MLE)	最大后验估计 (MAP)
最优参数的闭式解:		
$\mathbf{w}_{MLE/ERM}^*$	$(\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{X}\mathbf{y}$	
$\mathbf{w}_{MAP/SRM}^*$	$(\mathbf{X}\mathbf{X}^\top + \lambda\mathbf{I})^{-1}\mathbf{X}\mathbf{y}$	

问题思考:

- 为什么高斯噪声假设会自然导出平方损失?
- 最大似然估计和最大后验估计的根本区别是什么?
- 为什么 L_2 正则化可以解释为对参数加入零均值高斯先验?

(注: 详细定义和更多的内容请参考课程教材第二章、附录 D.)