

线性分类模型

数据科学与大数据技术专业

第 3 讲

1 导读

除本导读外, 本讲共有 7 个主体节. 它们围绕分类模型展开: 先建立分类任务和线性判别的基本框架, 再用信息论解释分类损失, 最后依次讨论 Logistic 回归、Softmax 回归、感知器、支持向量机以及这些模型之间的差异.

1. **分类问题与线性模型**: 说明分类任务的输出形式、线性分类器的判别方式以及常用评价指标.
2. **信息论与损失函数**: 说明极大似然、交叉熵、信息熵和 KL 散度如何为分类训练目标提供统一解释.
3. **Logistic 回归 (二分类)**: 说明二分类中如何把线性得分转成概率, 并用交叉熵学习参数.
4. **Softmax 回归 (多分类)**: 说明多分类中如何同时比较多个类别得分, 并得到类别概率分布.
5. **感知器 (Perceptron)**: 说明错误驱动的线性分类学习规则, 以及线性可分条件下的基本性质.
6. **支持向量机 (SVM)**: 说明最大间隔思想如何提升分类边界的稳定性, 以及核方法如何处理非线性分类.
7. **模型对比总结**: 对比 Logistic 回归、Softmax 回归、感知器和 SVM 在输出、损失、优化和适用场景上的差异.

如果细节都忘了: 最应该记住的是, 分类模型通常先产生类别得分, 再通过不同规则把得分变成标签、概率或间隔约束. Logistic/Softmax 强调概率解释, 感知器强调错了就改, SVM 强调把分类边界推得更稳.

问题思考:

- 同样是线性分类器, 为什么 Logistic 回归、感知器和 SVM 会得到不同的训练目标?

2 分类问题与线性模型

本节导读:

- **本节目的**: 建立分类任务的基本语言, 说明线性模型如何通过得分函数和决策边界完成分类.
- **为什么学**: 后续 Logistic 回归、Softmax、感知器和 SVM 都是在线性得分的基础上设计不同的输出解释和损失函数.

- **核心内容**: 分类问题输出离散标签, 线性分类器用超平面划分特征空间, 评价指标则从不同角度衡量预测是否正确.
- **最小例子**: 在二维平面上区分两类点时, 一条直线可以把平面分成两侧; 点落在哪一侧, 就对应模型预测的类别.
- **最该记住**: 线性分类的核心不是“直线”本身, 而是用得分函数定义决策边界.

1. 分类任务的基本特征

- 分类任务的目标是将输入映射到离散标签空间, 输出属于有限个类别之一.
- 与回归相比, 分类问题更关心决策边界和类别可分性; 在实际应用中, 决策边界往往依赖非线性特征表示.
- 典型应用包括图像识别、文本分类、医疗诊断和风险预警等.

2. 线性分类模型的判别方式

- 线性分类器通常先计算线性得分

$$f_c(\mathbf{x}) = \mathbf{w}_c^\top \mathbf{x} + b_c,$$

再根据得分输出类别.

- 在二分类中, 一个超平面即可将特征空间划分为两个半空间.
- 在多分类中, 常见策略包括:
 - **一对多 (One-vs-Rest, OvR)**: 为每个类别训练一个二分类器, 预测时选择得分最高的类别.
 - **一对一 (One-vs-One, OvO)**: 为任意两类分别训练一个二分类器, 共需 $\frac{C(C-1)}{2}$ 个分类器, 预测时通过投票决定类别.
 - **直接 $\arg \max$ 判别**: 同时为 C 个类别建立得分函数, 将 $\arg \max_c f_c(\mathbf{x})$ 作为预测结果.

3. 分类评价指标

- 给定测试集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$ 和预测结果 $\hat{y}^{(n)}$, 准确率与错误率分别为

$$\text{Accuracy} = \frac{1}{N} \sum_{n=1}^N \mathbb{I}(y^{(n)} = \hat{y}^{(n)}), \quad \text{ErrorRate} = 1 - \text{Accuracy}.$$

- 在二分类中, 混淆矩阵刻画了正负类上的局部表现:

	预测为正类 ($\hat{y} = 1$)	预测为负类 ($\hat{y} = 0$)
真实为正类 ($y = 1$)	真正例 (True Positive, TP)	假负例 (False Negative, FN)
真实为负类 ($y = 0$)	假正例 (False Positive, FP)	真负例 (True Negative, TN)

- 基于混淆矩阵, 常用指标包括:

- **精确率 (Precision)**:

$$\text{Precision} = \frac{TP}{TP + FP}.$$

它衡量所有“预测为正”的样本中有多少确为正类.

- **召回率 (Recall)** 或真正例率 (True Positive Rate, TPR):

$$\text{Recall} = \text{TPR} = \frac{TP}{TP + FN}.$$

它衡量所有真实正类样本中有多少被模型成功识别.

- F_1 值: 精确率与召回率的调和平均,

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}.$$

- F_β 值: 用于调节对精确率和召回率的偏好,

$$F_\beta = \frac{(1 + \beta^2)\text{PrecisionRecall}}{\beta^2\text{Precision} + \text{Recall}}, \quad \beta > 0.$$

其中 $\beta > 1$ 时更偏重召回率, $0 < \beta < 1$ 时更偏重精确率.

- **ROC 曲线与 AUC:** 对输出为概率或打分的二分类器, 可通过调整阈值来考察不同工作点下的性能.

- 在阈值 t 下,

$$\text{TPR}(t) = \mathbb{P}(s(\mathbf{x}) \geq t \mid y = 1), \quad \text{FPR}(t) = \mathbb{P}(s(\mathbf{x}) \geq t \mid y = 0).$$

以 FPR 为横轴、TPR 为纵轴即可得到 ROC 曲线.

- ROC 曲线越靠近左上角 $(0, 1)$, 模型区分能力通常越强; 若曲线接近对角线 $y = x$, 则模型与随机猜测接近.
- 若正负样本的打分分布相同, 则对任意阈值都有 $\text{TPR}(t) = \text{FPR}(t)$, 因而 ROC 曲线退化为对角线.
- AUC 是 ROC 曲线下的面积,

$$\text{AUC} = \int_0^1 \text{TPR}(u) du, \quad u = \text{FPR}.$$

它衡量模型在所有阈值下的整体排序能力.

- 更准确地说, AUC 还可解释为

$$\text{AUC} = \mathbb{P}(s(x^+) > s(x^-)) + \frac{1}{2}\mathbb{P}(s(x^+) = s(x^-)),$$

即随机抽取一个正样本和一个负样本时, 正样本得分不低于负样本的概率.

4. 典型线性分类器

- **Logistic 回归:** 用于二分类概率建模.
- **Softmax 回归:** Logistic 回归在多分类问题上的自然推广.
- **感知器:** 基于错误驱动的在线学习算法.
- **支持向量机 (SVM):** 通过最大化间隔提升分类鲁棒性.

问题思考:

- 线性模型如何实现多分类?
- 感知器与 Logistic 回归的主要区别是什么?

3 信息论与损失函数

本节导读:

- **本节目的:** 解释分类模型为什么常用负对数似然和交叉熵作为训练目标.
- **为什么学:** 分类准确率适合评价, 但不适合直接做梯度训练; 交叉熵提供了连续、可微且有概率解释的替代目标.
- **核心内容:** 最大化真实标签的条件概率等价于最小化负对数似然, 对 one-hot 标签而言也就是最小化交叉熵.
- **最小例子:** 若真实类别是猫, 模型给猫的概率为 0.9 时损失 $-\log 0.9$ 很小; 若只给 0.1, 损失 $-\log 0.1$ 会明显变大.
- **最该记住:** 交叉熵惩罚的是模型给真实类别的概率太低, 它把“分类正确”变成了可优化的概率目标.

1. 从极大似然到交叉熵

- 在分类问题中, 模型通常输出条件概率分布 $P(y | \mathbf{x}; \mathbf{w})$, 而不是直接输出类别标签.
- 给定训练集 $\{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$, 极大似然估计的目标是

$$\max_{\mathbf{w}} \prod_{i=1}^n P(y^{(i)} | \mathbf{x}^{(i)}; \mathbf{w}),$$

等价地, 也可最大化对数似然

$$\max_{\mathbf{w}} \sum_{i=1}^n \log P(y^{(i)} | \mathbf{x}^{(i)}; \mathbf{w}).$$

- 因此, 训练分类模型通常等价于最小化负对数似然 (Negative Log-Likelihood, NLL), 这正是交叉熵损失的来源.

2. 二分类中的交叉熵

- 设 $y \in \{0, 1\}$, 并记模型输出的正类概率为

$$p(\mathbf{x}) = P(y = 1 | \mathbf{x}; \mathbf{w}).$$

则条件概率可统一写为

$$P(y | \mathbf{x}; \mathbf{w}) = p(\mathbf{x})^y (1 - p(\mathbf{x}))^{1-y}.$$

- 对独立同分布样本取负对数似然, 得到经验风险

$$\mathcal{L}(\mathbf{w}) = - \sum_{i=1}^n \log P(y^{(i)} | \mathbf{x}^{(i)}; \mathbf{w}) = - \sum_{i=1}^n \left[y^{(i)} \log p(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log(1 - p(\mathbf{x}^{(i)})) \right].$$

- 若将真实标签看作分布 $[y, 1 - y]$, 将模型输出看作分布 $[p(\mathbf{x}), 1 - p(\mathbf{x})]$, 则上式恰好等于这两个分布的交叉熵. 因此, 在分类问题中最小化 NLL 与最小化交叉熵是一回事.

3. 信息熵, 交叉熵与 KL 散度

- 对离散分布 $p(x)$, 信息熵定义为

$$H(p) = - \sum_x p(x) \log p(x).$$

- 若用预测分布 $q(x)$ 去近似真实分布 $p(x)$, 则交叉熵定义为

$$H(p, q) = - \sum_x p(x) \log q(x).$$

- KL 散度定义为

$$\text{KL}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = H(p, q) - H(p).$$

因为 $H(p)$ 与模型参数无关, 所以最小化交叉熵与最小化 $\text{KL}(p\|q)$ 等价.

- **KL 散度的非负性:** 由不等式

$$\log t \leq t - 1, \quad \forall t > 0,$$

令 $t = \frac{q(x)}{p(x)}$, 则对所有满足 $p(x) > 0$ 的 x 有

$$\log \frac{q(x)}{p(x)} \leq \frac{q(x)}{p(x)} - 1.$$

两边乘以 $p(x)$ 并对 x 求和, 得到

$$\sum_x p(x) \log \frac{q(x)}{p(x)} \leq \sum_x (q(x) - p(x)) = 0.$$

因而

$$\text{KL}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \geq 0.$$

等号成立当且仅当 $p(x) = q(x)$ 在所有 $p(x) > 0$ 的位置上成立.

问题思考:

- 为什么交叉熵损失适合分类问题?
- KL 散度与交叉熵的关系是什么?

4 Logistic 回归 (二分类)

本节导读:

- **本节目的:** 说明二分类中如何把线性得分映射为正类概率, 并据此进行概率建模.

- **为什么学:** Logistic 回归是从线性模型走向概率分类器的最小例子, 也是理解神经网络输出层和交叉熵的重要基础.
- **核心内容:** 模型先计算 $\mathbf{w}^\top \mathbf{x}$, 再用 Sigmoid 得到 $P(y = 1 | \mathbf{x})$, 训练时最小化二分类交叉熵.
- **最小例子:** 垃圾邮件分类中, 线性得分越大, Sigmoid 输出越接近 1, 表示模型越相信邮件是垃圾邮件; 阈值 0.5 可用于给出最终标签.
- **最该记住:** Logistic 回归不是普通线性回归换个名字, 它输出的是二分类概率.

1. 模型形式与概率解释

- 为了书写简洁, 以下默认将偏置项并入特征向量. 于是模型先计算线性得分 $\mathbf{w}^\top \mathbf{x}$, 再通过 Sigmoid 函数输出正类概率.
- Logistic 函数定义为

$$\sigma(z) = \frac{1}{1 + \exp(-z)}.$$

因而

$$p(y = 1 | \mathbf{x}; \mathbf{w}) = \hat{y} = \sigma(\mathbf{w}^\top \mathbf{x}).$$

- 预测时, 常将 $\hat{y}$ 与阈值 0.5 比较, 或直接输出概率作为置信度.

2. 损失函数与经验风险

- Logistic 回归通常采用二元交叉熵作为损失函数.
- 在包含 N 个样本的训练集上, 平均经验风险写为

$$\mathcal{R}(\mathbf{w}) = -\frac{1}{N} \sum_{n=1}^N [y^{(n)} \log \hat{y}^{(n)} + (1 - y^{(n)}) \log(1 - \hat{y}^{(n)})].$$

3. 梯度计算与参数更新

- 由 Sigmoid 函数的导数

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)),$$

可得经验风险关于参数的梯度为

$$\begin{aligned} \frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} &= -\frac{1}{N} \sum_{n=1}^N \left(\frac{y^{(n)}}{\hat{y}^{(n)}} - \frac{1 - y^{(n)}}{1 - \hat{y}^{(n)}} \right) \hat{y}^{(n)} (1 - \hat{y}^{(n)}) \mathbf{x}^{(n)} \\ &= \frac{1}{N} \sum_{n=1}^N (\hat{y}^{(n)} - y^{(n)}) \mathbf{x}^{(n)}. \end{aligned}$$

- 若采用学习率为 α 的梯度下降法, 则参数更新为

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \alpha \frac{1}{N} \sum_{n=1}^N (\hat{y}_{\mathbf{w}_t}^{(n)} - y^{(n)}) \mathbf{x}^{(n)}.$$

4. 训练特性与停止策略

- Logistic 回归会持续根据“预测概率与真实标签之间的残差”调整参数, 即使样本已经被分对, 只要模型仍不够自信, 参数仍会继续更新.

- 在线性可分且不加正则化时, Logistic 损失往往没有有限的最优参数, 优化过程会倾向于不断增大 $\|\mathbf{w}\|$ 来把概率推向 0 或 1.
- 因此, 实际训练中常结合 L_2 正则化、早停策略或验证集监控, 以改善泛化能力与数值稳定性.

问题思考:

- 为什么 Logistic 回归输出概率?
- 交叉熵损失如何影响模型训练?

5 Softmax 回归 (多分类)

本节导读:

- **本节目的:** 把二分类概率建模推广到多分类, 说明多个类别得分如何转成一个概率分布.
- **为什么学:** 图像识别、文本分类等任务往往不止两个类别, 需要模型在所有类别之间进行相对比较.
- **核心内容:** Softmax 对所有类别 logits 做指数归一化, 使概率非负且总和为 1, 再用多分类交叉熵学习参数.
- **最小例子:** 对“猫、狗、车”三类, logits 为 (3, 1, 0) 时, Softmax 会给猫最高概率; 若三个 logits 同时加上同一个常数, 类别概率不变.
- **最该记住:** Softmax 概率只由类别得分的相对大小决定, 不是各类别彼此独立打分.

1. 从二分类到多分类

- Softmax 回归是 Logistic 回归在多分类问题上的自然推广.
- 对每个类别 $c \in \{1, \dots, C\}$, 模型先计算线性得分

$$z_c = \mathbf{w}_c^\top \mathbf{x} + b_c,$$

再通过归一化映射得到类别概率.

- 预测时通常选择最大概率对应的类别, 即 $\arg \max_c \hat{y}_c$.

2. Softmax 概率映射

- 对得分向量 $\mathbf{z} = (z_1, \dots, z_C)$, Softmax 定义为

$$\hat{y}_c = \text{softmax}(z_c) = \frac{\exp(z_c)}{\sum_{j=1}^C \exp(z_j)}, \quad c = 1, \dots, C.$$

- 该映射保证每个 $\hat{y}_c > 0$, 且 $\sum_{c=1}^C \hat{y}_c = 1$, 因而输出可以解释为类别条件概率分布.

3. 损失函数与模型优化

- 若第 n 个样本的真实标签采用 one-hot 向量 $\mathbf{y}^{(n)} = (y_1^{(n)}, \dots, y_C^{(n)})$, 模型预测为 $\hat{\mathbf{y}}^{(n)} = (\hat{y}_1^{(n)}, \dots, \hat{y}_C^{(n)})$, 则多元交叉熵经验风险可写为

$$\mathcal{R} = -\frac{1}{N} \sum_{n=1}^N \sum_{c=1}^C y_c^{(n)} \log \hat{y}_c^{(n)}.$$

- 当 Softmax 与交叉熵结合使用时, 对每个样本的得分分量 $z_c^{(n)}$ 有

$$\frac{\partial \mathcal{R}}{\partial z_c^{(n)}} = \hat{y}_c^{(n)} - y_c^{(n)},$$

这一梯度形式非常简洁, 因而适合用梯度下降及其变种进行优化.

问题思考:

- Softmax 回归与 Logistic 回归的联系与区别是什么?
- 多分类问题中, Softmax 函数的核心作用是什么?

5.1 补充: 为什么使用 Softmax

1. 最大熵视角

- 设得分向量 $\mathbf{x} = (x_1, \dots, x_C) \in \mathbb{R}^C$, 希望构造概率分布 $\mathbf{p} = (p_1, \dots, p_C)$, 满足 $p_i > 0$, $\sum_{i=1}^C p_i = 1$, 并满足期望约束

$$\sum_{i=1}^C p_i x_i = \mu.$$

- 在仅保留这些已知信息的前提下, 最大熵原则要求求解

$$\max_{\mathbf{p}} \left\{ -\sum_{i=1}^C p_i \log p_i \right\} \quad \text{s.t.} \quad \sum_{i=1}^C p_i = 1, \quad \sum_{i=1}^C p_i x_i = \mu.$$

- 引入拉格朗日乘子后, 可得解的形式为

$$p_i = \frac{\exp(\lambda x_i)}{\sum_{j=1}^C \exp(\lambda x_j)}.$$

当 $\lambda = 1$ 时, 就得到标准的 Softmax 形式.

2. 平移不变性与数值稳定性

- 对任意常数 $c \in \mathbb{R}$, 有

$$\text{softmax}(x_i + c) = \frac{\exp(x_i + c)}{\sum_{j=1}^C \exp(x_j + c)} = \frac{\exp(x_i)}{\sum_{j=1}^C \exp(x_j)}.$$

因而

$$\text{softmax}(\mathbf{x} + c\mathbf{1}) = \text{softmax}(\mathbf{x}).$$

- 这表明 Softmax 只依赖各类别得分之间的相对差异. 实际计算中, 常先减去 $\max_i x_i$ 来避免指数溢出.

3. 从 Logistic 到 Softmax

- 在二分类中, Logistic 回归通过 Sigmoid 函数把一个实数得分映射为正类概率.
- 在多分类中, 我们需要把 C 个类别的得分同时映射为和为 1 的概率分布. 对每个得分取指数并统一归一化, 就得到 Softmax.
- 因而, Softmax 可以看作 Logistic 回归在多分类情形下的直接推广.

4. 与交叉熵的配合

- 设原始得分为 $\mathbf{z} = (z_1, \dots, z_C)$, 预测概率为

$$\hat{y}_k = \frac{\exp(z_k)}{\sum_{j=1}^C \exp(z_j)}, \quad k = 1, \dots, C.$$

对应的交叉熵损失为

$$\mathcal{L} = - \sum_{k=1}^C y_k \log \hat{y}_k.$$

- 由

$$\log \hat{y}_k = z_k - \log \sum_{j=1}^C \exp(z_j),$$

可得

$$\frac{\partial \mathcal{L}}{\partial z_m} = \hat{y}_m - y_m.$$

这一结果说明梯度恰好等于“预测概率减去真实概率”, 因而推导和实现都非常直接.

5. 物理视角

- Softmax 的形式与统计物理中的玻尔兹曼分布一致:

$$P(E_i) = \frac{\exp\left(-\frac{E_i}{kT}\right)}{\sum_j \exp\left(-\frac{E_j}{kT}\right)}.$$

- 若把类别得分看成负能量, 或把温度参数吸收到得分缩放中, 就得到与 Softmax 相同的形式. 这说明 Softmax 也可以理解为一种“得分越高, 概率越大”的能量模型分布.

6. 历史补充

- Softmax 这一名称通常追溯到 John S. Bridle 在 1989 年关于分类网络输出概率解释的工作 [1]. 该工作明确将归一化指数映射用于多分类神经网络输出层, 也促成了 Softmax 在机器学习中的广泛使用.

6 感知器 (Perceptron)

本节导读:

- **本节目的:** 介绍最早的线性分类学习算法之一, 说明如何根据分类错误直接修正参数.
- **为什么学:** 感知器展示了“错误驱动更新”的基本思想, 也揭示了线性可分和非线性可分之间的关键差别.

- **核心内容:** 对被分错的样本, 感知器按真实类别方向移动决策边界, 使该样本下一次更可能被分对.
- **最小例子:** 若二分类标签取 $y \in \{-1, 1\}$, 样本满足 $y\mathbf{w}^\top \mathbf{x} \leq 0$ 时被分错, 可用 $\mathbf{w} \leftarrow \mathbf{w} + y\mathbf{x}$ 修正参数.
- **最该记住:** 感知器只在犯错时更新, 但它不输出概率, 也不直接最大化分类间隔.

1. 模型定义

- 感知器提出于 1958 年, 是早期机器学习中的经典线性分类模型.
- 对二分类标签 $y \in \{+1, -1\}$, 感知器使用线性判别函数并通过符号函数作出预测:

$$\hat{y} = \text{sign}(\mathbf{w}^\top \mathbf{x}).$$

2. 错误驱动的更新规则

- 感知器的训练目标是找到一组参数, 使所有样本满足

$$y^{(n)}(\mathbf{w}^\top \mathbf{x}^{(n)}) > 0.$$

- 当样本 $(\mathbf{x}, y)$ 被分错, 即

$$y(\mathbf{w}^\top \mathbf{x}) \leq 0,$$

就执行更新

$$\mathbf{w}_{t+1} = \mathbf{w}_t + y\mathbf{x}.$$

- 这一更新可看作对感知器损失

$$L_{\text{perc}}(\mathbf{w}; \mathbf{x}, y) = \max(0, -y\mathbf{w}^\top \mathbf{x})$$

的一次随机次梯度下降. 这里使用的是感知器损失, 而不是带单位间隔的 Hinge 损失.

3. 为何只对错分样本更新

- 若样本已经满足 $y\mathbf{w}^\top \mathbf{x} > 0$, 则其感知器损失为 0, 不会推动参数继续变化.
- 若样本被分错, 则更新后有

$$y(\mathbf{w}_{t+1}^\top \mathbf{x}) = y(\mathbf{w}_t^\top \mathbf{x}) + y^2 \mathbf{x}^\top \mathbf{x},$$

其中第二项恒非负, 因而该样本的分类裕度会朝正确方向增大.

4. 收敛性与局限

- 若训练数据线性可分, 感知器算法会在有限步内收敛到某个可分解.
- 若数据本身不可线性分, 标准感知器通常不会收敛, 参数可能持续振荡.

5. 与 Logistic 回归的比较

- 感知器只关心“是否分对”, 一旦样本处在正确一侧就停止更新.

- Logistic 回归则基于概率残差更新参数, 即使样本已经分对, 只要预测概率与真实标签仍有偏差, 参数就可能继续调整.

问题思考:

- 感知器算法为何只对分错样本更新?
- 感知器收敛性的前提条件是什么?

7 支持向量机 (SVM)

本节导读:

- **本节目的:** 说明支持向量机如何通过最大化分类间隔得到更稳定的线性分类边界.
- **为什么学:** 仅仅把训练样本分对并不唯一, 间隔思想提供了在多个可行分类边界中选择更稳健边界的原则.
- **核心内容:** SVM 寻找能正确分类并尽可能远离最近训练样本的超平面, 核方法则把这个思想扩展到非线性特征空间.
- **最小例子:** 两类点已经线性可分时, 可能有很多条直线能分开它们; SVM 会选择离两类最近点都尽量远的那条直线.
- **最该记住:** SVM 的核心是最大间隔, 真正决定边界的是少数支持向量.

1. 最大间隔思想

- 虽然许多线性分类器都能找到把两类样本分开的超平面, 但不同超平面的鲁棒性并不相同.
- 支持向量机的核心思想是在所有可分超平面中寻找间隔最大的那个, 以提升模型对扰动的稳定性.
- 与最优超平面距离最近的样本称为**支持向量**, 它们决定了最终的决策边界.

2. 硬间隔 SVM

- 设分类超平面为 $\mathbf{w}^\top \mathbf{x} + b = 0$, 对样本 $(\mathbf{x}^{(n)}, y^{(n)})$ 其中 $y^{(n)} \in \{+1, -1\}$, 其几何间隔可写为

$$\gamma^{(n)} = \frac{y^{(n)}(\mathbf{w}^\top \mathbf{x}^{(n)} + b)}{\|\mathbf{w}\|}.$$

- 若数据严格线性可分, 可要求所有样本满足 $y^{(n)}(\mathbf{w}^\top \mathbf{x}^{(n)} + b) \geq 1$, 并求解

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y^{(n)}(\mathbf{w}^\top \mathbf{x}^{(n)} + b) \geq 1, \quad n = 1, \dots, N. \end{aligned}$$

- 这一形式通过固定函数间隔为 1 消除了缩放不确定性, 等价于最大化最小几何间隔.

3. 软间隔 SVM

- 实际数据往往含有噪声, 甚至本身不可线性分. 此时可以引入松弛变量 $\xi_n \geq 0$, 允许部分样本落入间隔内部或被错分.

- 软间隔 SVM 的优化问题为

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & y^{(n)}(\mathbf{w}^\top \mathbf{x}^{(n)} + b) \geq 1 - \xi_n, \quad n = 1, \dots, N, \\ & \xi_n \geq 0, \quad n = 1, \dots, N. \end{aligned}$$

- 当 $0 < \xi_n < 1$ 时, 样本虽然仍被分对, 但已经落入间隔内部; 当 $\xi_n \geq 1$ 时, 样本可能被错分.
- 超参数 $C > 0$ 用于平衡“最大化间隔”和“惩罚违约”这两个目标: C 越大, 对违约样本惩罚越强; C 越小, 模型越强调间隔和鲁棒性.

4. Hinge 损失视角

- 在适当重参数化下, 软间隔 SVM 等价于最小化 Hinge 损失与正则化项之和:

$$\min_{\mathbf{w}, b} \sum_{n=1}^N \max(0, 1 - y^{(n)}(\mathbf{w}^\top \mathbf{x}^{(n)} + b)) + \frac{\lambda}{2} \|\mathbf{w}\|^2.$$

- Hinge 损失只要分类裕度未超过 1 就继续惩罚, 因而不仅要求“分对”, 还要求“分得足够远”.

5. 与其他分类损失的比较

- 若记 $m = yf(\mathbf{x})$ 为分类裕度, 则不同损失函数对大裕度样本的处理方式不同.
- **平方损失**: $\mathcal{L} = (1 - m)^2$. 它对已经正确且裕度很大的样本仍会持续惩罚, 因而通常不如专门的分类损失自然.
- **Logistic 损失**: $\mathcal{L} = \log(1 + \exp(-m))$. 该损失光滑、便于优化, 且具有概率解释.
- **感知器损失**: $\mathcal{L} = \max(0, -m)$. 只要样本分对, 损失就为零.
- **Hinge 损失**: $\mathcal{L} = \max(0, 1 - m)$. 它比感知器损失更强调安全间隔, 因而更有利于提升鲁棒性.

6. 优化方法

- 经典 SVM 常通过对偶问题转化为凸二次规划来求解, 代表算法包括 SMO(Sequential Minimal Optimization).
- 在大规模问题中, 也可以采用随机次梯度下降等近似优化方法.

问题思考:

- SVM 为何要最大化间隔?
- 软间隔 SVM 如何处理噪声数据?

8 模型对比总结

本节导读:

- **本节目的**: 把本讲几个线性分类模型放在一起比较, 理清它们在目标函数和输出解释上的差异.

- **为什么学:** 多个模型形式相似, 但训练准则和适用场景不同; 对比能避免把它们只记成一组名字.
- **核心内容:** Logistic/Softmax 侧重概率建模, 感知器侧重在线错误修正, SVM 侧重间隔最大化.
- **最小例子:** 面对同一批线性可分数据, 感知器只要找到一条能分开的边界就可能停止, SVM 还会继续偏向间隔最大的边界, Logistic 回归则学习类别概率.
- **最该记住:** 没有一个分类器在所有场景都最好, 选择模型要看是否需要概率、间隔、在线更新或非线性扩展.

1. 模型选择的主要考虑

- 若需要直接输出二分类概率, 通常选择 Logistic 回归.
- 若需要多分类概率输出, 通常选择 Softmax 回归.
- 若数据线性可分且关注在线更新, 感知器是最简单的基线方法.
- 若更关注分类间隔与鲁棒性, 则 SVM 往往更有优势.

2. 典型模型对比

模型	激活函数	损失函数	优化方法	主要应用场景
线性回归	-	均方误差	最小二乘/梯度下降	回归任务
Logistic 回归	Sigmoid	二元交叉熵	梯度下降	二分类概率预测
Softmax 回归	Softmax	多元交叉熵	梯度下降	多分类概率预测
感知器	符号函数 (sgn)	感知器损失	在线更新/随机梯度法	线性可分分类
SVM	符号函数 (sgn)	Hinge 损失 + L_2 正则	二次规划/SMO/次梯度法	最大间隔分类

问题思考:

- 不同模型的损失函数有何异同?
- 线性模型在实际应用中应如何选择?

(注: 详细定义和更多内容请参考课程教材第 3 章及附录 E.)

参考文献

- [1] John S. Bridle. Probabilistic interpretation of feedforward classification network outputs, with relationships to statistical pattern recognition. In *Neurocomputing: Algorithms, Architectures and Applications*, pages 227–236. Springer Berlin Heidelberg, Berlin, Heidelberg, 1990.