机器学习概述

《神经网络与深度学习》第2讲

什么是学习？

从阅读、听讲、研究、实践等活动中获得知识或技能。

新华词典

A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.

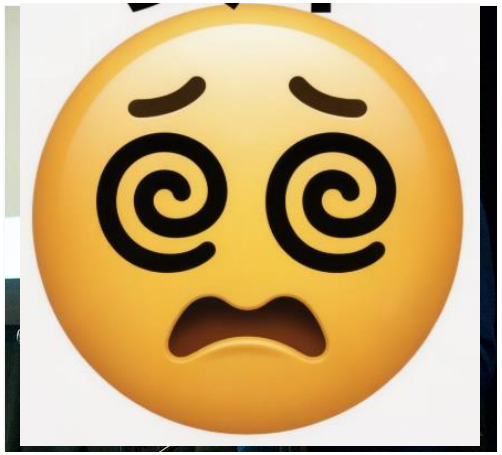

Tom Mitchell

什么是学习？

对于许多问题，很难手工编写出正确的行为

- 识别人和物体
- 理解人类语音

机器学习方法：编写一种算法，使其能够从数据或经验中自动学习。

为什么你可能想使用学习算法？

- 很难手工编码出一个解决方案（例如视觉、语音）
- 系统需要适应不断变化的环境（例如垃圾邮件检测）
- 希望系统的表现优于人类程序员
- 隐私/公平（例如对搜索结果进行排序）

什么是学习？

它和统计学很相似……

- 两个领域都试图从数据中发现模式
- 两个领域都大量依赖微积分、概率论和线性代数，并共享许多核心算法

但它不是统计学！

- 统计学更关注帮助人得出可靠结论；机器学习更关注构建自主智能体
- 统计学更强调可解释性和数学严谨性；机器学习更强调预测性能、可扩展性和自主性

与 AI 的关系

如今，机器学习常常与人工智能一起被提及

AI 并不总是意味着一个基于学习的系统

- 符号推理
- 基于规则的系统
- 树搜索
- 等等

基于学习的系统 → 基于数据学习得到 → 更灵活，擅长解决模式识别问题。

与人类学习的关系

人类学习是：

- 非常高效地利用数据
- 一个完整的多任务系统（视觉、语言、运动控制等）
- 至少需要几年时间 :)

为了实现特定目的，机器学习最终并不一定要看起来像人类学习。

它可能会借鉴生物系统的想法，例如神经网络。

它的表现可能比人类更好，也可能更差。

机器学习 ≈ 构建一个映射

- 语音识别 $f($ 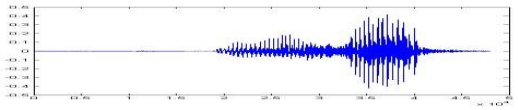 $)=$ “你好”
- 图像识别 $f($ $)=$ “猫”
- 围棋 $f($ $)=$ “5-5” (落子位置)
- 对话系统 $f($ “你好” $)=$ “今天天气真不错”

用户输入　　机器

如何构建映射

从大量数据中学习规律

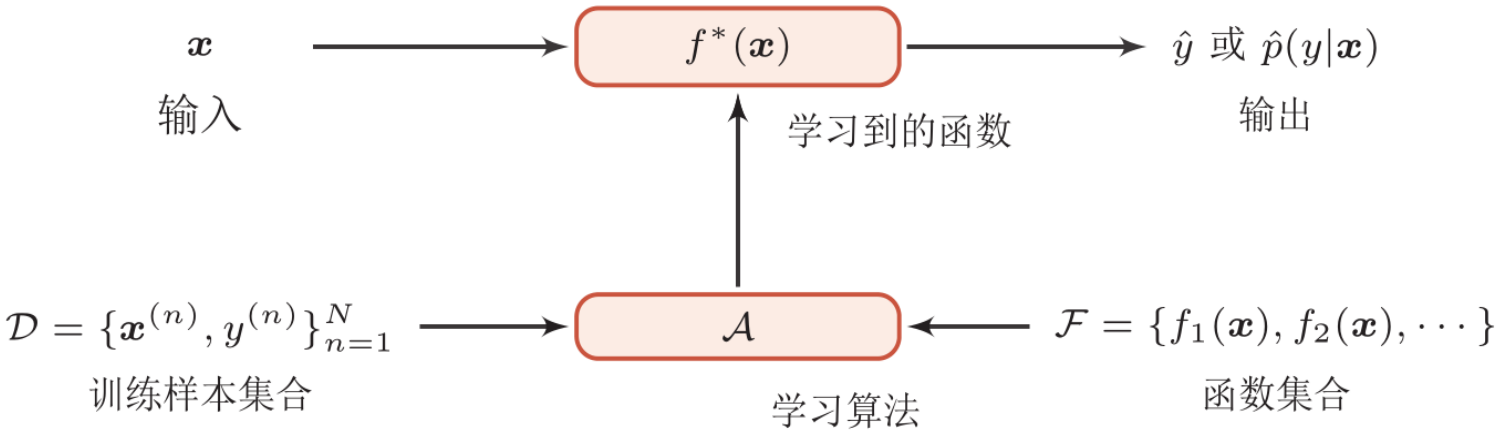

不是拟合!

什么是机器学习？

通俗地讲，机器学习（Machine Learning，ML）就是让计算机从数据中进行自动学习，得到某种知识（或规律），并利用这些规律对未知数据进行预测.

Machine learning (**ML**) is a field of study in artificial intelligence concerned with the development and study of statistical algorithms that can learn from data and generalize to unseen data, and thus perform tasks without explicit instructions.[1]

WIKIPEDIA
The Free Encyclopedia

描述、解释、预测、控制.

机器学习的历史

- 1957 — 感知机 (Perceptrons) 算法（以电路形式实现！）
- 1959 — Arthur Samuel 编写了一个基于学习的跳棋程序
- 1969 — Minsky 和 Papert 证明线性模型的极限
- 1980s — 基础想法
  - 联结主义心理学家探索了认知的神经模型
  - 1984 — Leslie Valiant 提出 PAC 学习理论
  - 1988 —Geoffrey Hinton 发现反向传播算发
  - 1988 — Judea Pearl 引入 Bayesian 网络

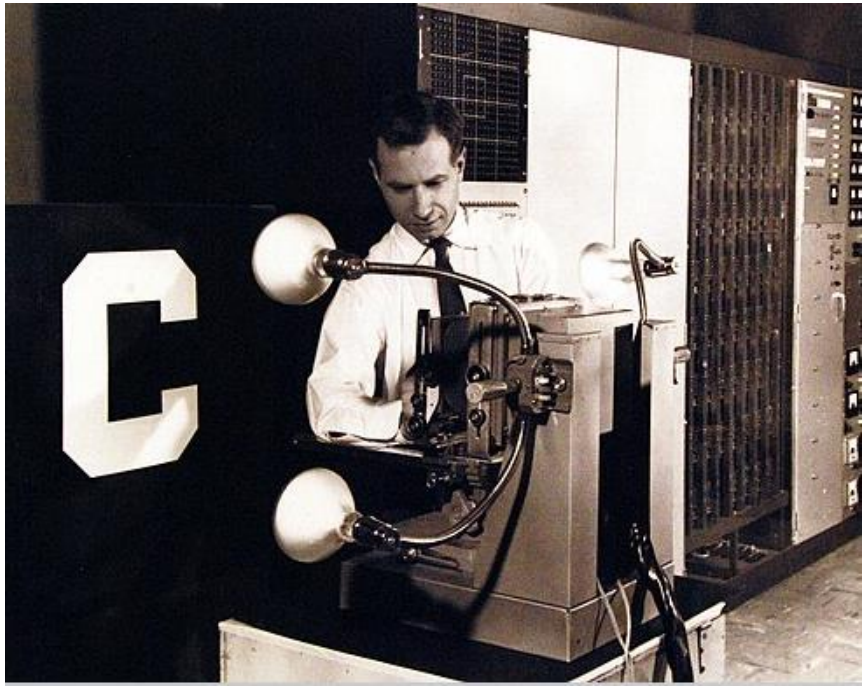

机器学习的历史

- 1990s — AI寒冬
- 但回头看，90年代在某种程度上也是机器学习的黄金时代
  - Markov chain Monte Carlo
  - 变分推断
  - 核方法与支持向量机
  - 卷积网络
  - 强化学习
- 2000s — 应用AI领域（视觉、NLP等）开始采用机器学习

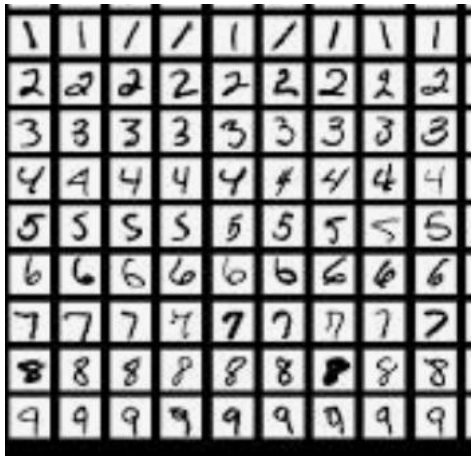

机器学习的历史

- 2010s — 深度学习
  - 2010-2012 — 神经网络在语音转文本和目标识别方面打破了以往纪录
  - 科技行业的采用率不断提高
  - 2016 — AlphaGo击败了人类围棋冠军
  - 2018 — 生成逼真的图像和视频
  - 2020 — GPT-3
  - 2024 — DeepSeek
- 现在 — AI 不能做什么？

回归: 电影票房预测

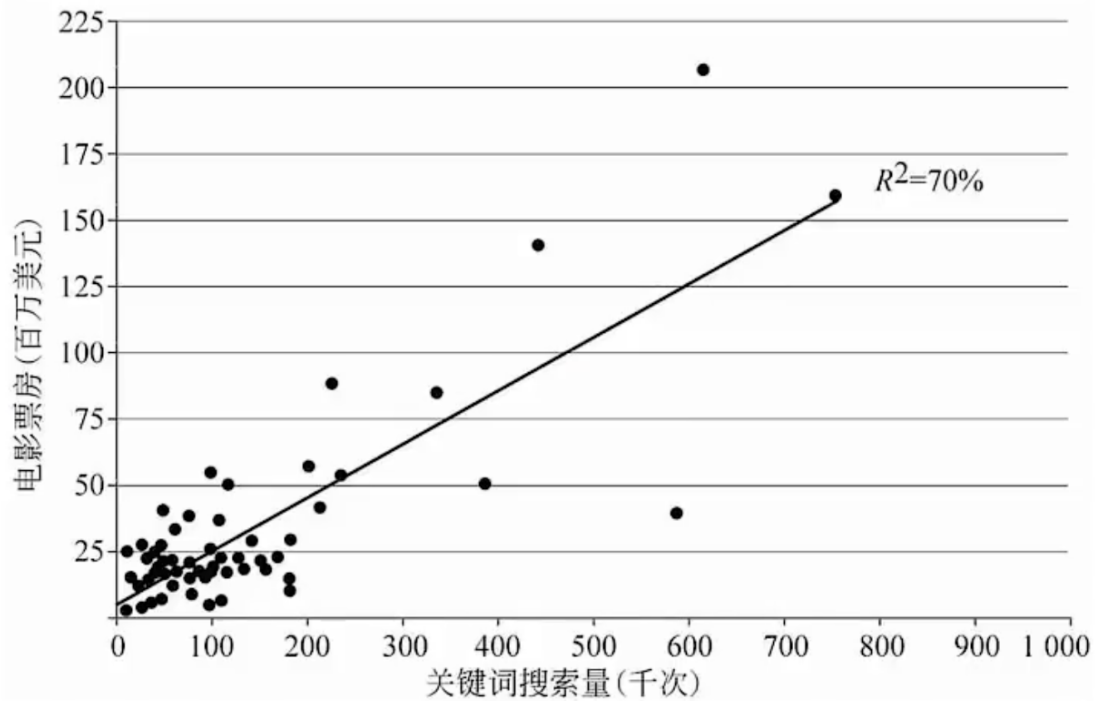

评分
导演影响力
演员影响力
电影档期
电影投资方
电影续集
电影制作技术
R-squared
Adjusted R-squared
F-statistic
Prob(F-statistic)

回归(Regression)问题

回归: 公司股价预测

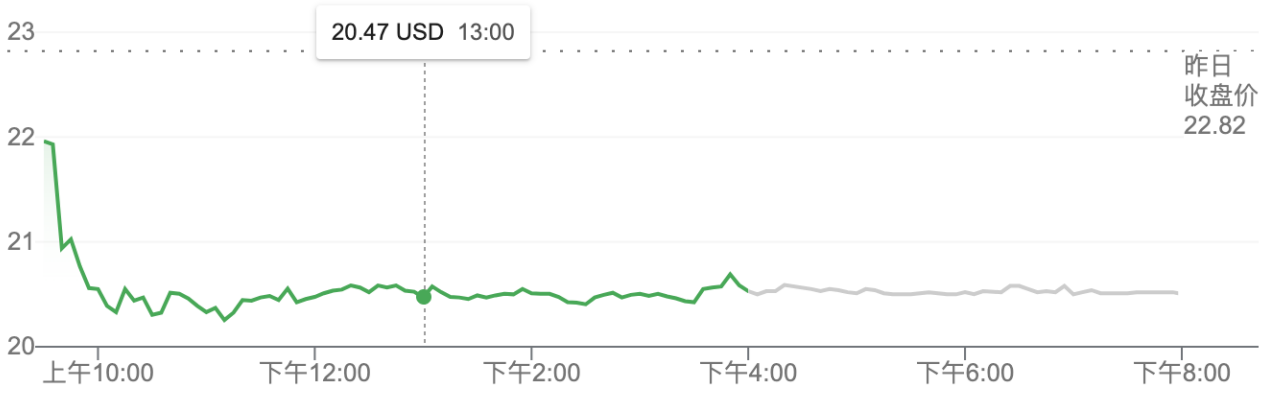

开盘	21.96	市值	85.52亿	52 周高点	31.77
最高	21.96	市盈率	-	52 周低点	9.63
最低	20.14	股息收益率	-		

现金流
资产负债表
经济情况
产业型态
...

股价

回归(Regression)问题

幻方量化

人工智能公司 ⋮

幻方量化是一家总部位于中国浙江省杭州市的对冲基金、量化基金和人工智能公司，成立于2015年。

分类: 手写数字识别

Fig. 8. All of the misclassified MNIST test digits using our method (63 out of 10,000). The text above each digit indicates the example number followed by the true label and the assigned label.

Belongie et al. PAMI 2002

分类(Classification)问题

分类: 人脸检测

分类(Classification)问题

分类: 邮件分类

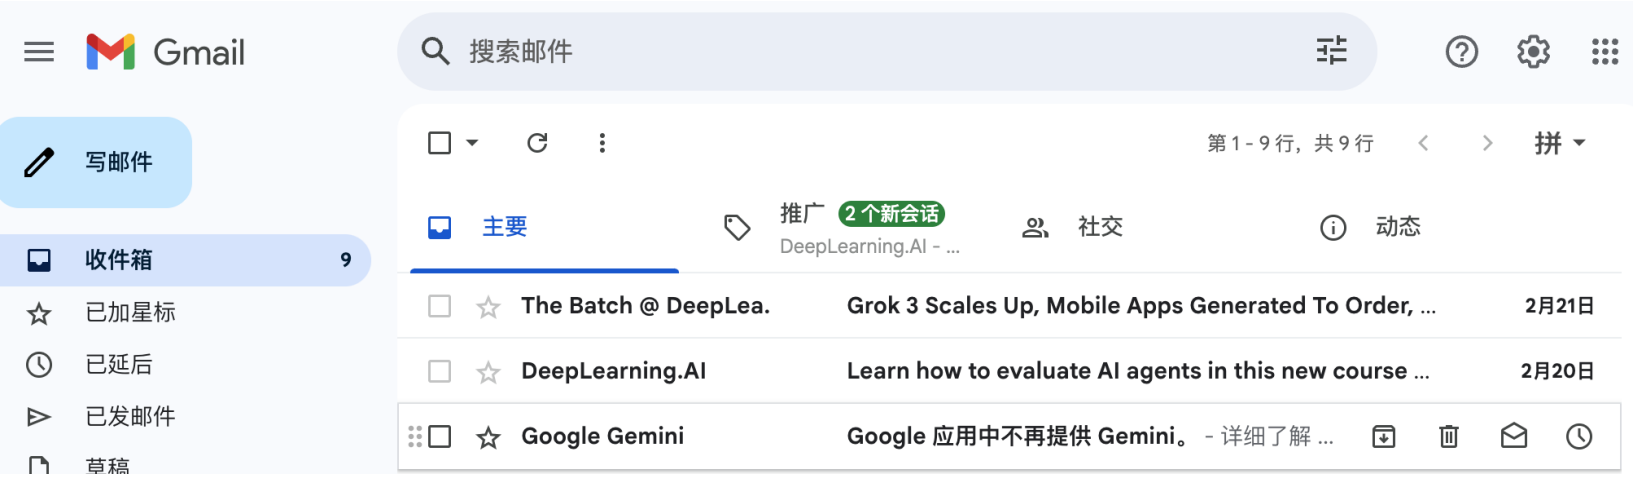

分类(Classification)问题

聚类: 图像聚类

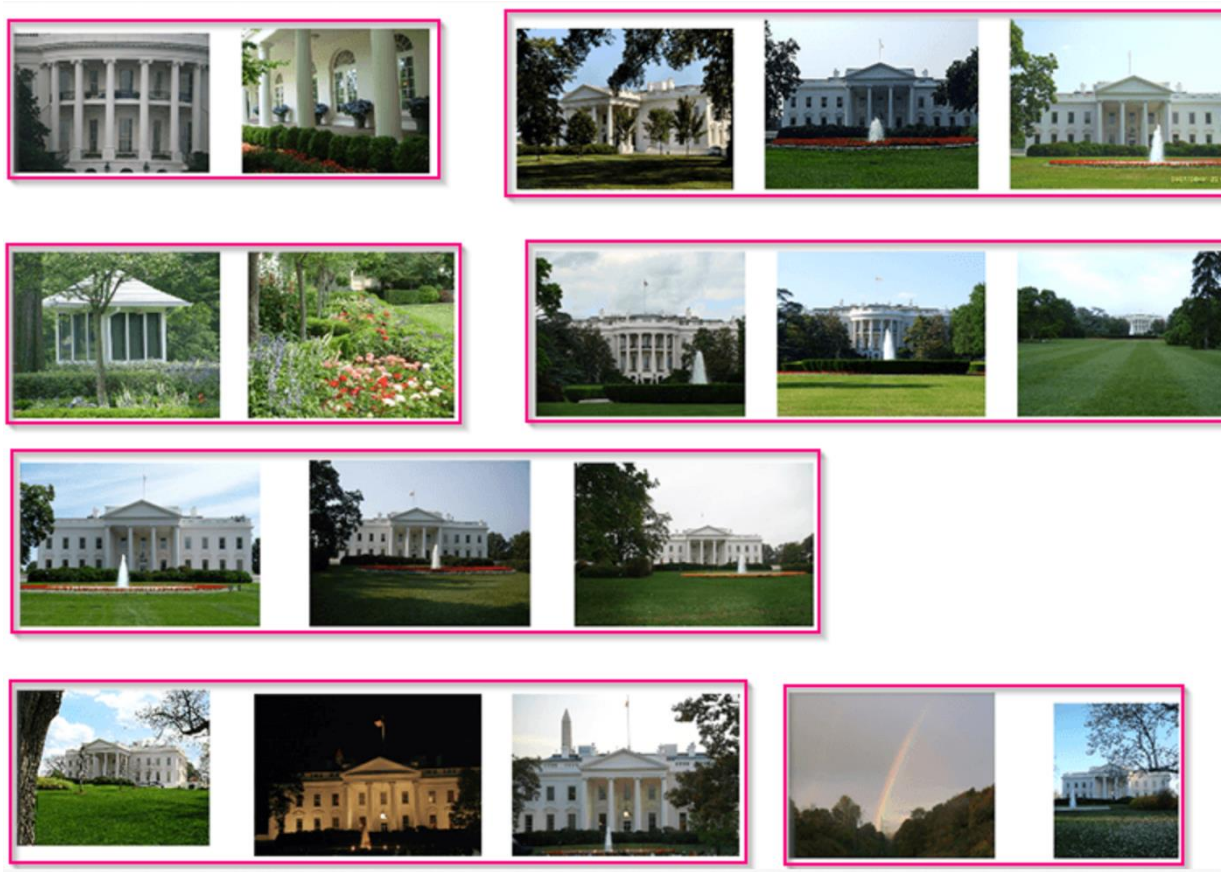

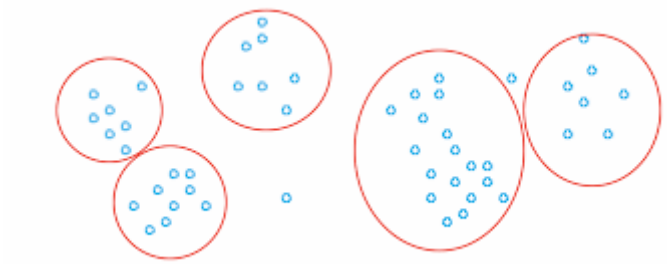

强化学习

AlphaGo

OpenAI Five

强化学习-通过与环境交互来学习

例: 自动驾驶

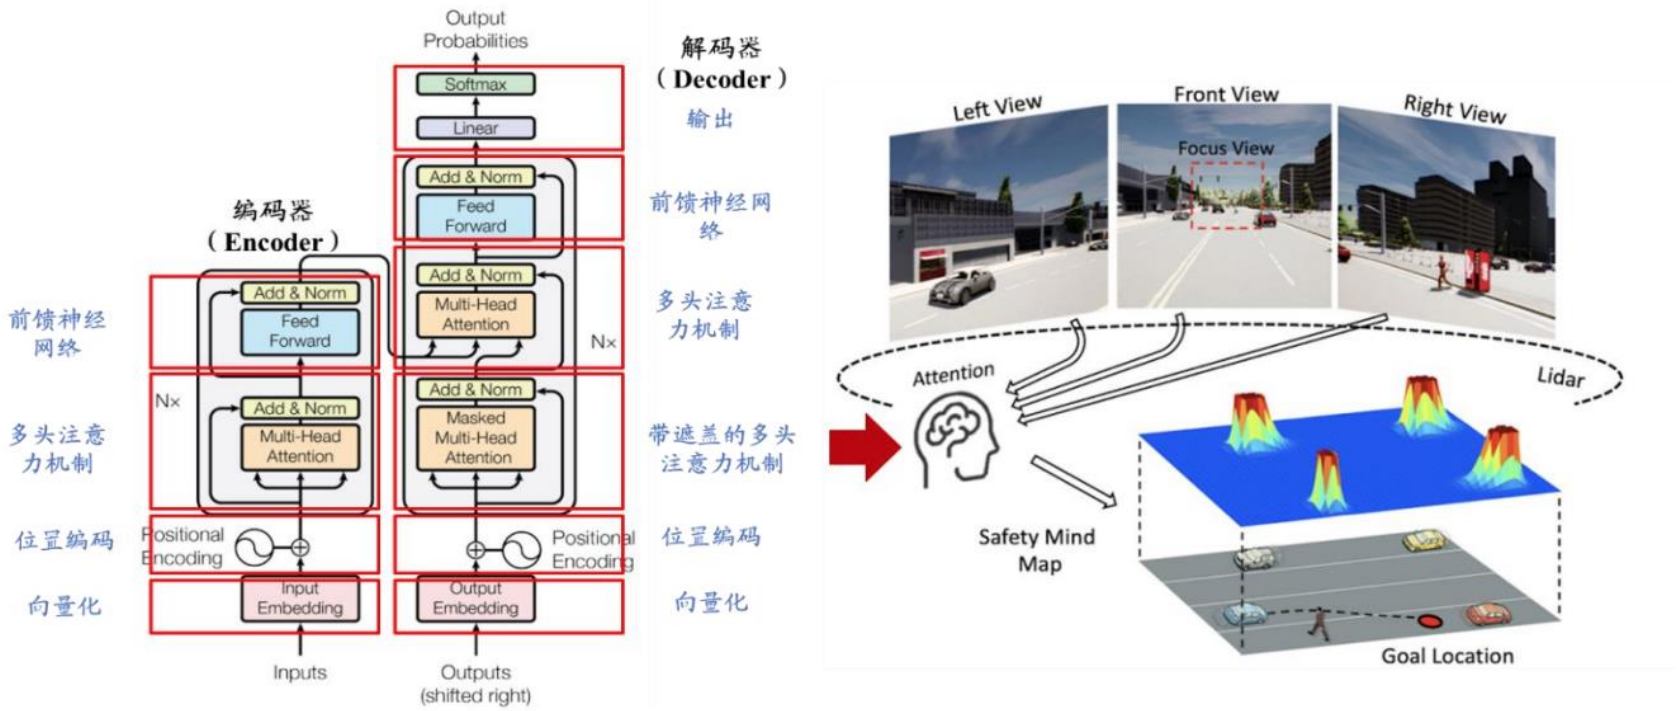

资料来源：《Attention Is All You Need》（Ashish Vaswani 等）、《Safety-Enhanced Autonomous Driving Using Interpretable Sensor Fusion Transformer》（Hao Shao 等）、开源证券研究所

总结: 常见机器学习类型

表 2.1　三种机器学习类型的比较

	监督学习	无监督学习	强化学习
训练样本	训练集 $\{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$	训练集 $\{\boldsymbol{x}^{n}\}_{n=1}^{N}$	智能体和环境交互的轨迹 τ 和累积奖励 G_τ
优化目标	$y = f(\boldsymbol{x})$ 或 $p(y\|\boldsymbol{x})$	$p(\boldsymbol{x})$ 或带隐变量 $\boldsymbol{z}$ 的 $p(\boldsymbol{x}\|\boldsymbol{z})$	期望总回报 $\mathbb{E}_\tau[G_\tau]$
学习准则	期望风险最小化 最大似然估计	最大似然估计 最小重构错误	策略评估 策略改进

典型的监督学习

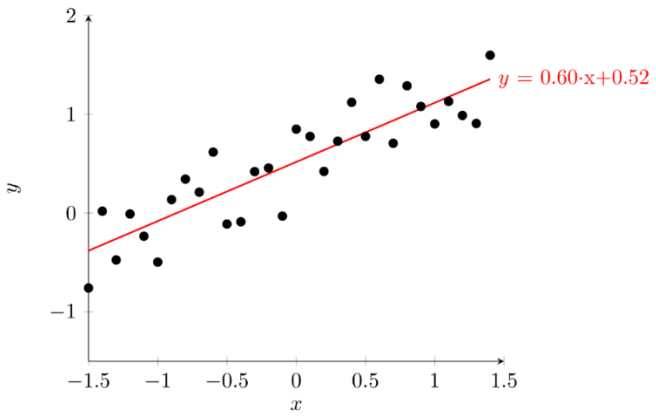

回归

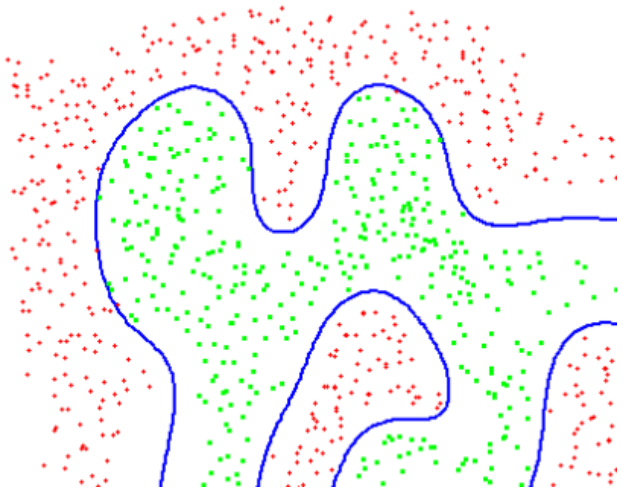

分类

典型的无监督学习

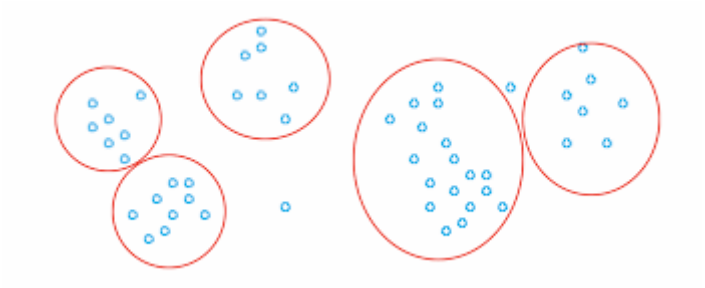

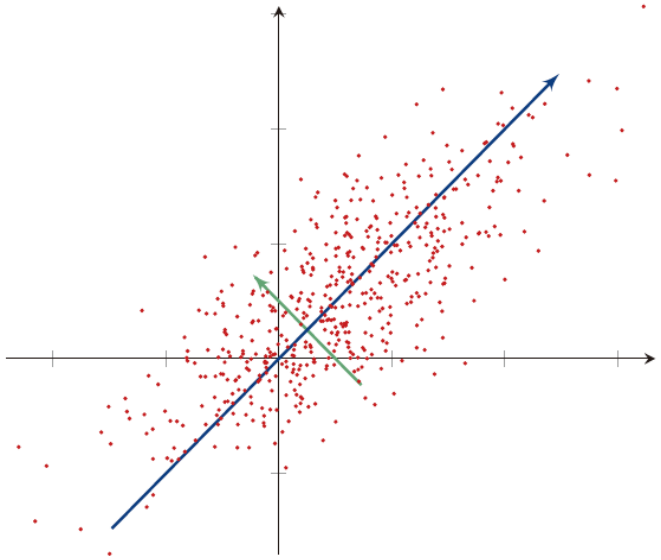

图 9.1　主成分分析

聚类

降维

提纲

- 机器学习定义
- 机器学习类型
- **机器学习要素**
- 泛化与正则化
- 回顾概率论基础

机器学习的四个要素

通俗地讲，机器学习（Machine Learning，ML）就是让计算机从数据中进行自动学习，得到某种知识（或规律），并利用这些规律对未知数据进行预测.

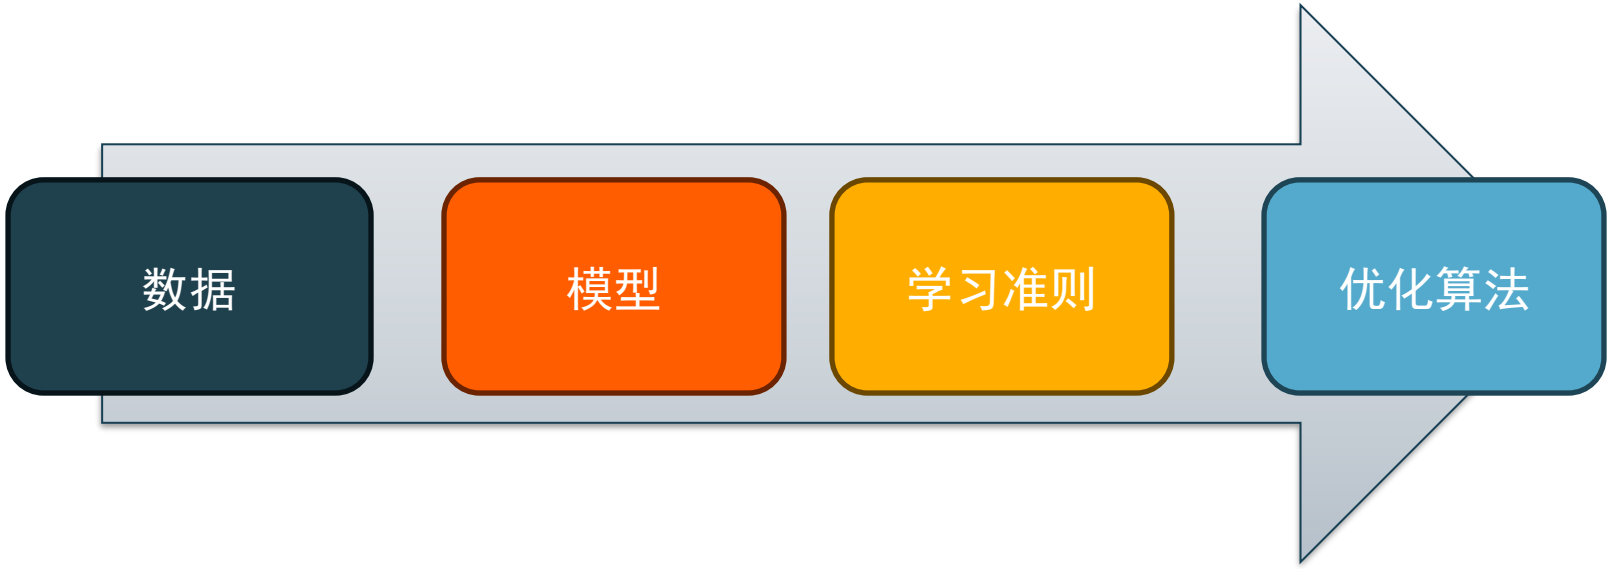

数据

特征	$\boldsymbol{x}$	标签	y
颜色	x_1	好坏	
大小	x_2		
产地	x_3		
品牌	x_4		

一组样本构成的集合称数据集

分为训练集和测试集

$$\mathcal{D} = \{(\boldsymbol{x}^{(1)}, y^{(1)}), (\boldsymbol{x}^{(2)}, y^{(2)}), \cdots, (\boldsymbol{x}^{(N)}, y^{(N)})\}.$$

对于样本 $\boldsymbol{x}$， 找一个函数 $f^*(\boldsymbol{x})$来预测其标签的值

$$\hat{y} = f^*(\boldsymbol{x}),$$

模型

以线性回归（Linear Regression）为例

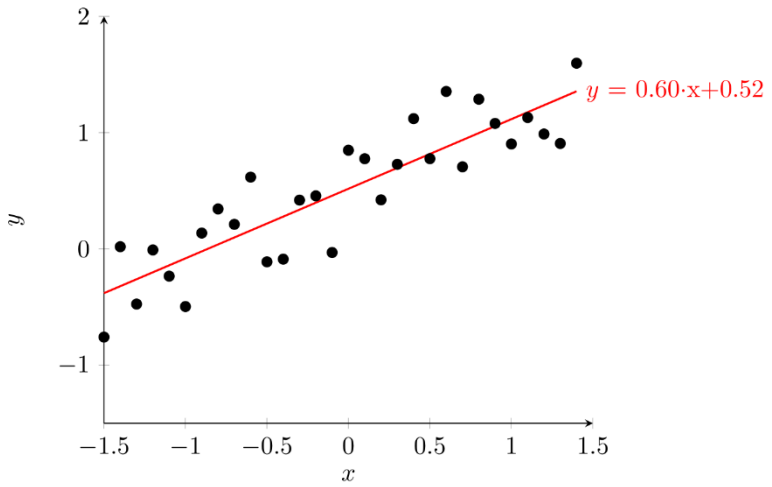

$$f(\boldsymbol{x};\theta) = \boldsymbol{w}^{\top}\boldsymbol{x} + b,$$

线性模型

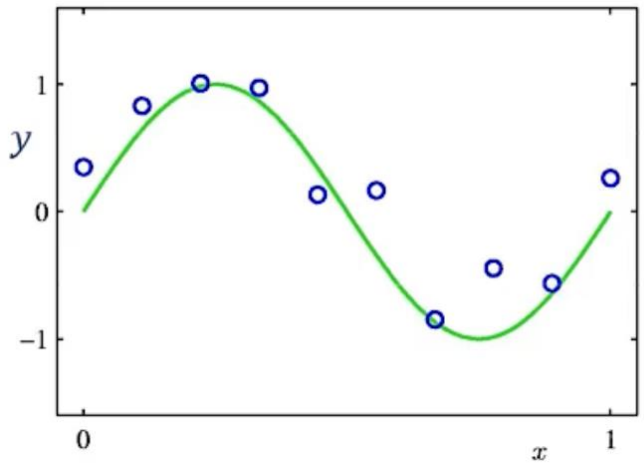

$$f(\boldsymbol{x};\theta) = \boldsymbol{w}^{\top}\phi(\boldsymbol{x}) + b,$$

非线性模型

若 $\phi(x)$ 也是可学习的非线性基函数, 则 $f(x,\theta)$等价于神经网络.

学习准则

一个好的模型应该在所有的可能取值上都与真实一致

$$|f(\boldsymbol{x}, \theta^*) - y| < \epsilon, \qquad \forall (\boldsymbol{x}, y) \in \mathcal{X} \times \mathcal{Y},$$

损失函数

一个非负实数函数，用来量化模型预测和真实标签之间的差异.

$$\mathcal{L}(y, f(\boldsymbol{x}; \theta)) = \begin{cases} 0 & \text{if } y = f(\boldsymbol{x}; \theta) \\ 1 & \text{if } y \neq f(\boldsymbol{x}; \theta) \end{cases}$$

0-1损失函数

$$\mathcal{L}(y, f(\boldsymbol{x}; \theta)) = \frac{1}{2}\big(y - f(\boldsymbol{x}; \theta)\big)^2.$$

平方损失函数

学习准则

期望风险

$$\mathcal{R}(\theta) = \mathbb{E}_{(\boldsymbol{x},y)\sim p_r(\boldsymbol{x},y)}[\mathcal{L}(y, f(\boldsymbol{x};\theta))]$$

↓

真实数据分布

经验风险

训练数据：$\mathcal{D} = \{x^{(n)}, y^{(n)}\}, \quad i \in [1, N]$

$$\mathcal{R}_{\mathcal{D}}^{emp}(\theta) = \frac{1}{N}\sum_{n=1}^{N}\mathcal{L}(y^{(n)}, f(\boldsymbol{x}^{(n)};\theta)).$$

在选择合适的损失函数后，寻找一个参数θ^*，使得经验风险函数最小化.

$$\theta^* = \arg\min_{\theta} \mathcal{R}_{\mathcal{D}}^{emp}(\theta)$$

机器学习问题转化成为一个最优化问题？

最优化问题

机器学习问题转化成为一个最优化问题

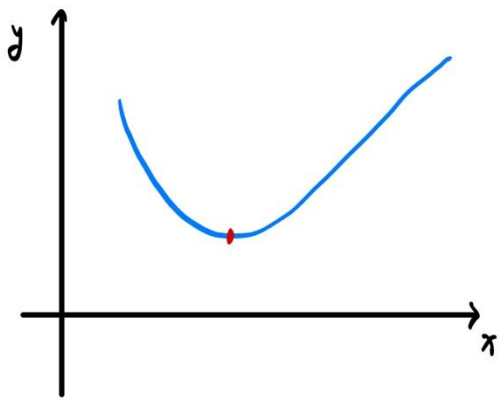

凸

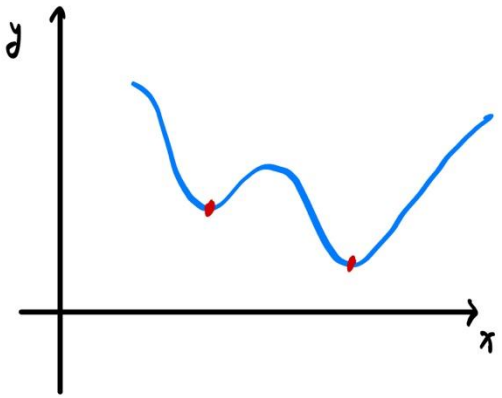

非凸

$$\min_{x} f(x)$$

梯度下降法 (Gradient Descent)

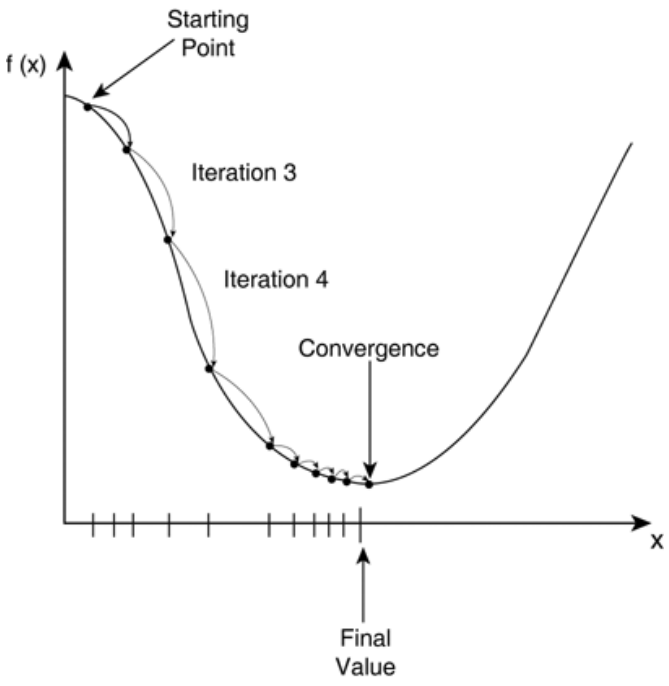

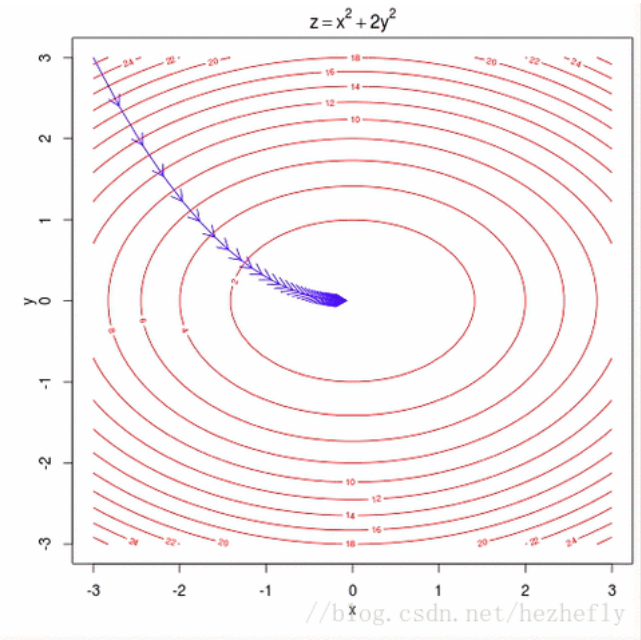

$$\theta_{t+1} = \theta_t - \alpha \frac{\partial \mathcal{R}(\theta)}{\partial \theta_t}$$

$$= \theta_t - \alpha \frac{1}{N} \sum_{i=1}^{N} \frac{\partial \mathcal{L}(\theta_t; x^{(i)}, y^{(i)})}{\partial \theta}.$$

搜索步长α中也叫学习率（Learning Rate）

学习率是十分重要的超参数

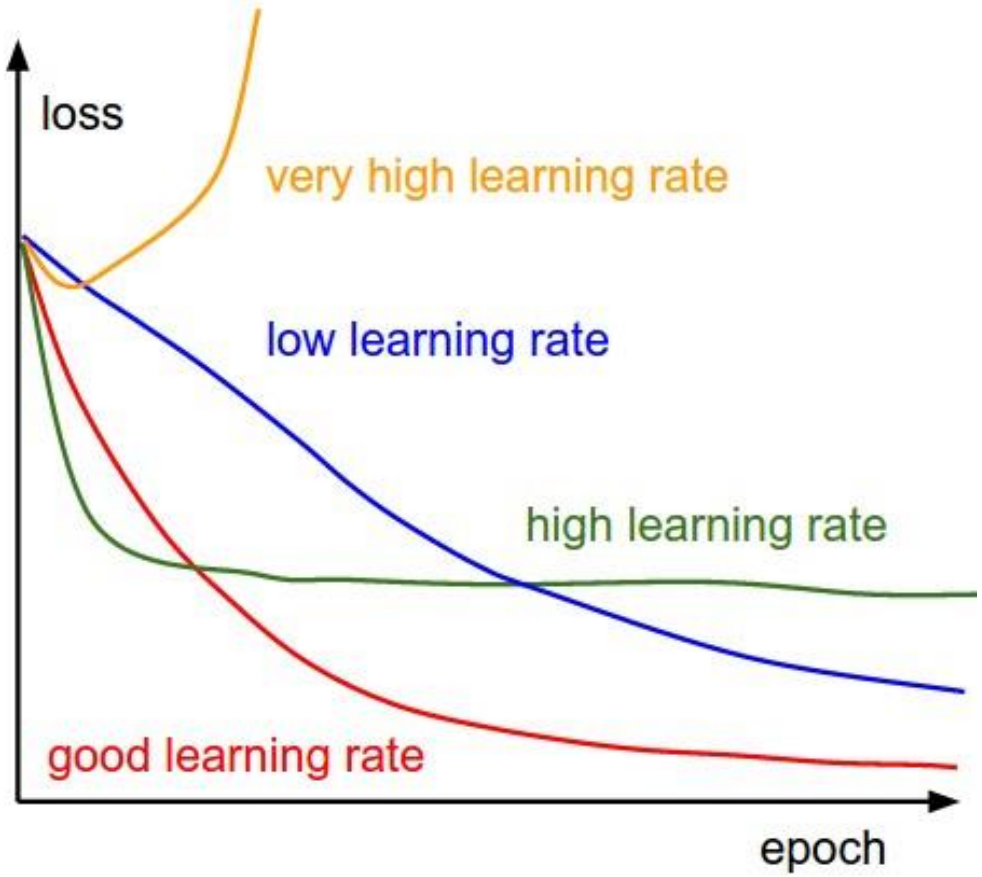

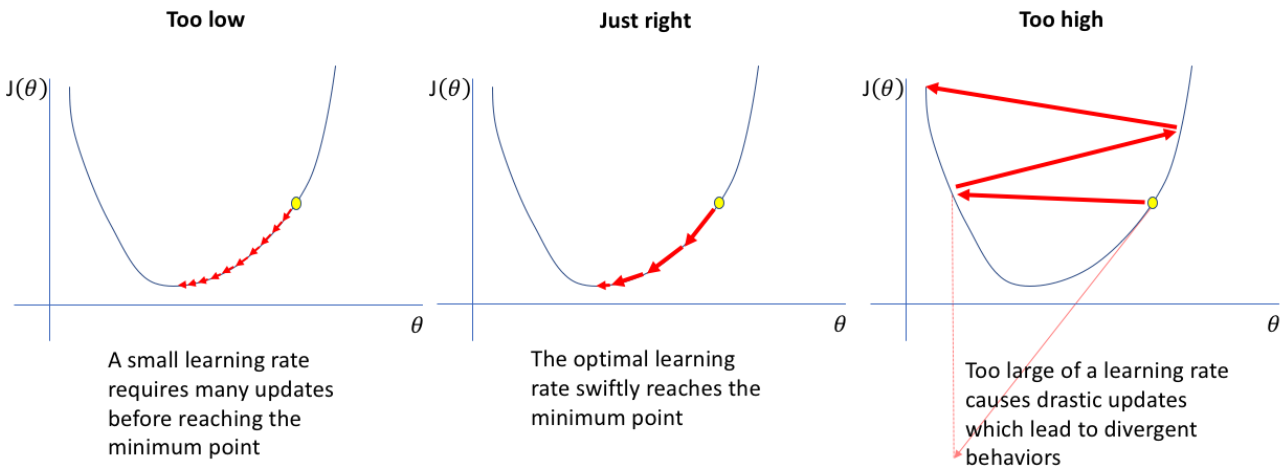

随机梯度下降法

随机梯度下降法 每次迭代时只采集一个样本

$$\theta \leftarrow \theta - \alpha \frac{\partial \mathcal{L}(\theta; x^{(n)}, y^{(n)})}{\partial \theta};$$

$$\begin{aligned}\theta_{t+1} &= \theta_t - \alpha \frac{\partial \mathcal{R}(\theta)}{\partial \theta_t} \\ &= \theta_t - \alpha \frac{1}{N} \sum_{i=1}^{N} \frac{\partial \mathcal{L}(\theta_t; x^{(i)}, y^{(i)})}{\partial \theta}.\end{aligned}$$

批量梯度下降法

当经过足够次数的迭代时，随机梯度下降也可以收敛到局部最优解

- 优点：每次计算开销小，支持在线学习
- 缺点：无法充分利用计算机的并行计算能力

小批量（Mini-Batch）随机梯度下降法

- 随机选取一小部分训练样本, 计算梯度并更新参数
- 既可以兼顾随机梯度下降法的优点，也可以提高训练效率

随机梯度下降法

算法 2.1　随机梯度下降法

输入: 训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$ $\boxed{\text{验证集 } \mathcal{V}}$ 学习率 α

```
随机初始化 θ;
repeat
    对训练集 D 中的样本 [随机排序];
    for n = 1 ··· N do
        从训练集 D 中选取样本 (x^(n), y^(n));
        θ ← θ − α ∂L(θ; x^(n), y^(n)) / ∂θ;        // 更新参数
    end
until 模型 f(x; θ) 在验证集 V 上的错误率不再下降;
```

输出: θ

机器学习 = 优化？

机器学习 = 优化？ NO！

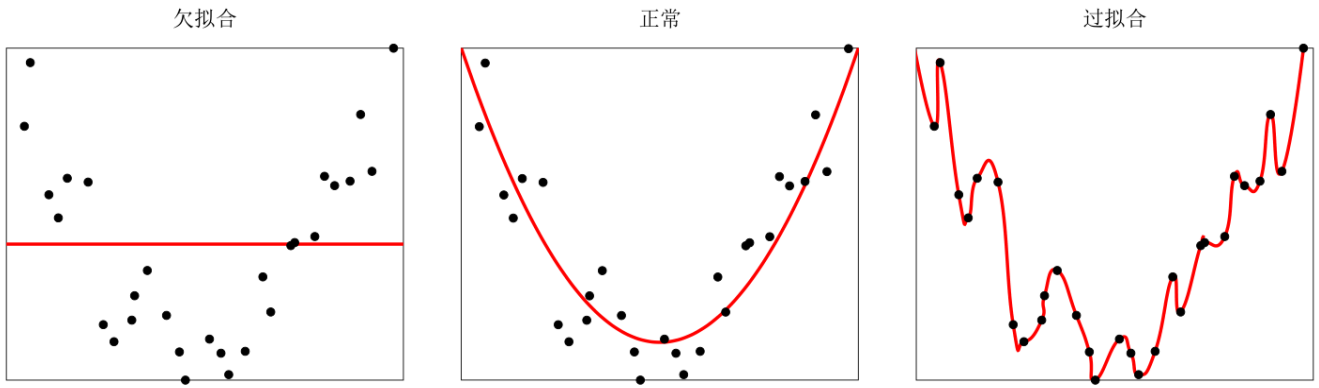

- 过拟合: 经验风险最小化原则很容易导致模型在训练集上错误率很低, 但是在未知数据上错误率很高.
- 过拟合问题往往是由于训练数据少和噪声等原因造成的

泛化误差

期望风险

$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x},y)\sim p(\mathbf{x},y)}[\mathcal{L}(f(\mathbf{x}), y)],$$

经验风险

$$\mathcal{R}_{\mathcal{D}}^{emp}(\theta) = \frac{1}{N}\sum_{n=1}^{N}\mathcal{L}(y^{(n)}, f(x^{(n)}, \theta))$$

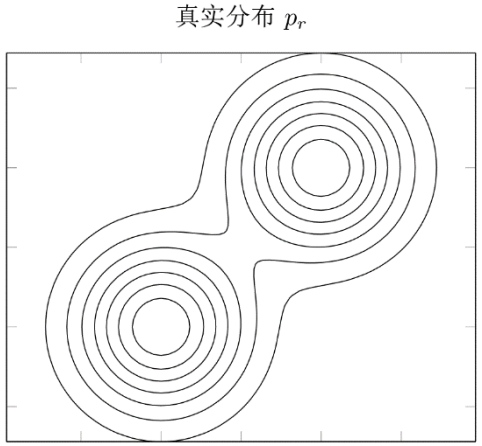

$\neq$

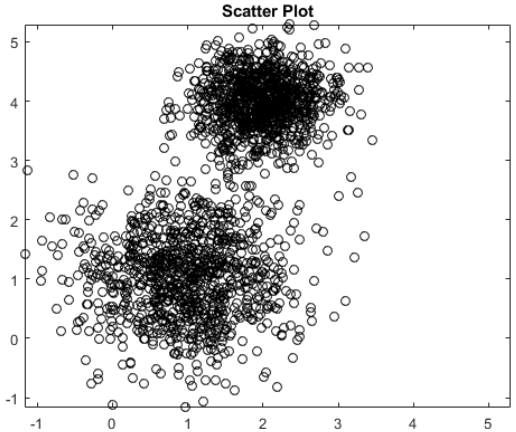

$$\mathcal{G}_{\mathcal{D}}(f) = \mathcal{R}(f) - \mathcal{R}_{\mathcal{D}}^{emp}(f)$$

泛化误差

如何减少泛化错误？

优化

经验风险最小

正则化

降低模型复杂度

正则化（regularization）

所有损害优化的方法都是正则化

增加优化约束

L1/L2约束、数据增强

干扰优化过程

权重衰减、随机梯度下降、提前停止

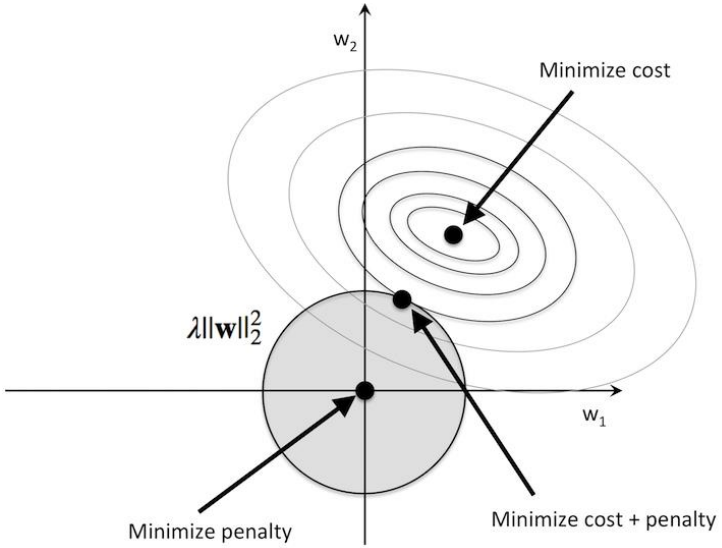

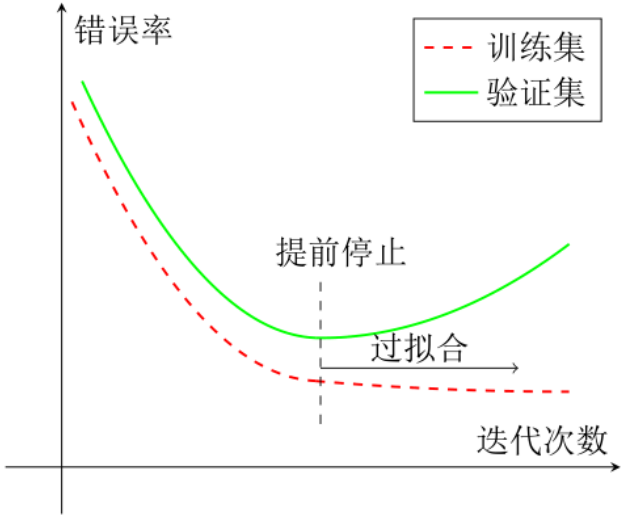

提前停止

我们使用一个验证集 (Validation Dataset) 来测试每一次迭代的参数在验证集上是否最优. 如果在验证集上的错误率不再下降, 就停止迭代.

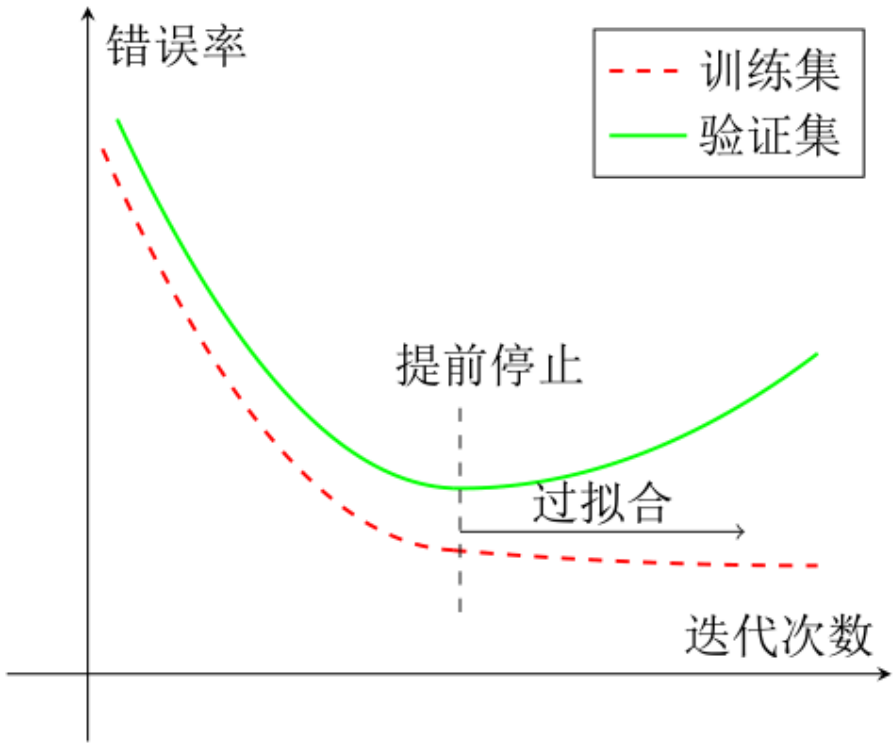

谢谢！