线性回归

《神经网络与深度学习》第2讲

概率论基础

概率论中的基本概念

样本空间（Sample Space）	随机试验的结果全体，记为Ω.
样本点（Sample Point）	Ω中的元素ω，随机试验的结果.
事件（Event)	Ω的一个子集，包含若干样本点.
事件域（Event Field)	Ω的一个子集族，记为$\mathcal{F}$. 满足：包含Ω，对取补和可数并的运算封闭.
概率（Probability)	定义在$\mathcal{F}$上的集合函数P，满足非负性、规范性和可数可加性. 刻画事件发生的可能性大小.

概率论中的基本概念

概率空间（Probability Space） 样本空间, 事件域, 概率的全体 $(\Omega, \mathcal{F}, P)$

例： 随机掷一个骰子, 样本空间为骰子的点数.

例： [0,1] 上随机选取某个实数, 样本空间为 [0,1].

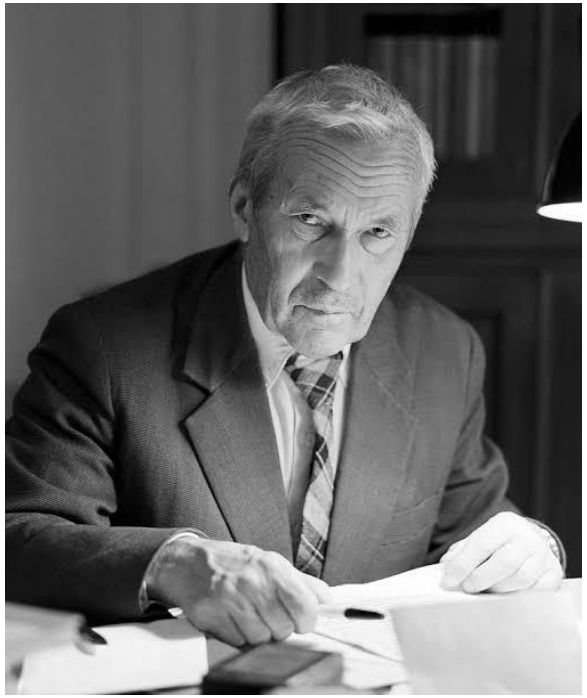

Kolmogorov (1903-1987)

现代概率论的开拓者，建立了概率论的严密公理体系.

概率论中的基本概念

随机变量(Random Variable)　Ω 到 $\mathbb{R}$ 的 Borel 可测的映射 X.

概率分布(Probability Distribution)

一个随机变量X取每种可能值的概率.

分布函数（Distribution Function)

$$F(x) = P(X \leq x), \qquad -\infty < x < +\infty$$

随机变量 X 服从分布函数 $F(x)$ 记为 $X \sim F(x)$.

概率论中的基本概念

离散随机变量

取有限个值 $\{x_1, \cdots, x_N\}$ 的随机变量，概率分布为

$$P(X = x_n) = p(x_n), \qquad \forall n \in \{1, \cdots, N\}$$

例：随机掷一个骰子，得到的点数就可以看成一个随机变量X，其取值为 $\{1, 2, 3, 4, 5, 6\}$

伯努利分布 （Bernoulli Distribution）

在一次试验中，事件A出现的概率为μ，不出现的概率为$1-\mu$. 若用变量X表示事件A出现的次数，则X的取值为0和1，其相应的分布为

$$p(x) = \mu^x (1-\mu)^{(1-x)}$$

概率论中的基本概念

二项分布（Binomial Distribution）

在n次伯努利分布中，若以变量X表示事件A出现的次数，则X的取值为$\{0, \dots, n\}$，且相应的概率分布为

$$P(X = k) = \binom{n}{k}(1-\mu)^{n-k}\mu^k, \qquad k = 1, \cdots, n$$

二项式系数，表示从n个元素中取出k个元素而不考虑其顺序的组合的总数.

概率论中的基本概念

连续随机变量

概率分布用概率密度函数（Probability Density Function）$p(x)$ 表示

$$\int_{-\infty}^{+\infty} p(x)\mathrm{d}x = 1,$$

概率密度函数与分布函数有如下关系

$$F(x) = \int_{-\infty}^{x} p(t)dt, \qquad -\infty < x < +\infty$$

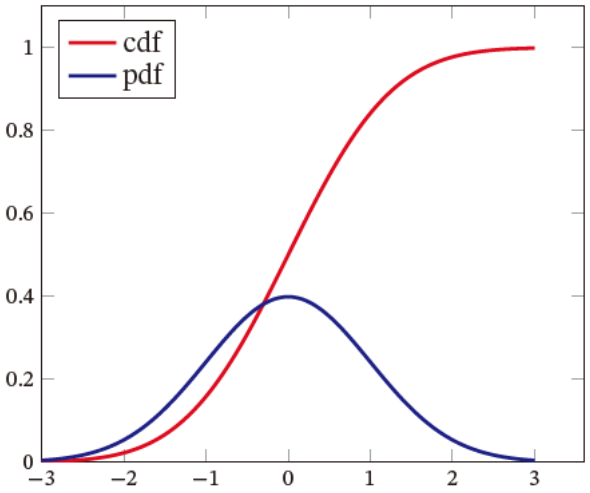

概率论中的基本概念

均匀分布（Uniform Distribution）

$$p(x) = \begin{cases} \frac{1}{b-a}, & a \le x \le b \\ 0, & x < a \text{或} x > b \end{cases}$$

高斯分布（ Gaussian Distribution ）

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

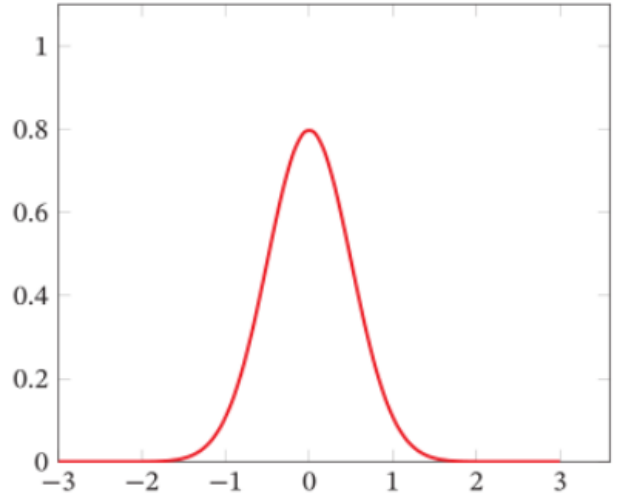

概率论中的基本概念

随机向量　一组随机变量构成的向量.

离散随机向量的联合分布函数(Joint Distribution Function)为

$$F(x_1,\cdots,x_K)=P(X_1<x_1,\cdots,X_K<x_K)$$

联合随机向量的联合概率密度函数(Joint Probability Density Function)满足

$$p(\boldsymbol{x})=p(x_1,\cdots,x_K)\geq 0,$$

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty}p(x_1,\cdots,x_K)\mathrm{d}x_1\cdots\mathrm{d}x_K=1.$$

且

$$F(x_1,\cdots,x_K)=\int_{-\infty}^{x_1}\cdots\int_{-\infty}^{x_K}p(x_1,\cdots,x_K)\,\mathrm{d}x_1\cdots\mathrm{d}x_K$$

概率论中的基本概念

边际分布（Marginal Distribution）

设二维离散随机向量(X,Y)取值为 $X \in \{x_i\}, Y \in \{y_i\}$，概率分布为：

$$P\left(X = x_i, Y = y_j\right) = p\left(x_i, y_j\right).$$

则边际分布定义为：

$$P(X = x_i) = p_1(x_i) = \sum_j p(x_i, y_j)$$

$$P\left(Y = y_j\right) = p_2\left(y_j\right) = \sum_i p(x_i, y_j)$$

概率论中的基本概念

边际分布（Marginal Distribution）

系\行业	IT	教育	
计算机	0.4	0.1	0.5
数学	0.1	0.4	0.5
	0.6	0.4	

概率论中的基本概念

条件概率

对于离散随机向量(X,Y)，已知$X=x$的条件下，随机变量$Y=y$的条件概率分布为：

$$P(Y=y\mid X=x)=\frac{P(X=x,Y=y)}{P(X=x)}=\frac{p(x,y)}{p_1(x)}$$

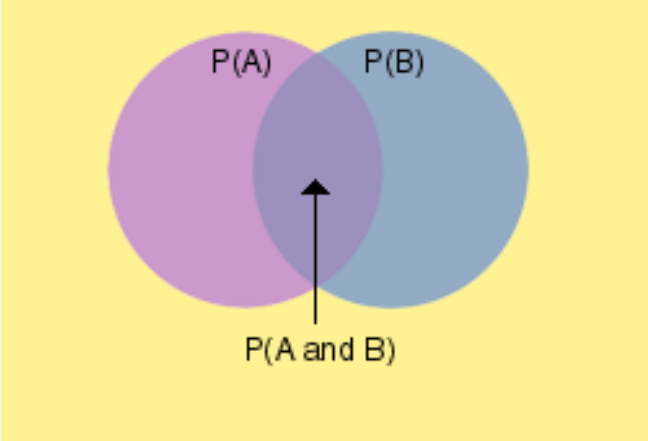

概率论中的基本概念

例

系\行业	IT	教育	
计算机	0.4	0.1	0.5
数学	0.1	0.4	0.5
	0.6	0.4	

已知专业为计算机，从事教育行业的概率多大?

概率论中的基本概念

贝叶斯定理

两个条件概率 $p(x|y)$ 和 $p(y|x)$之间的关系为

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

如何根据观测到的数据 x 去更新我们对原因 y 的概率判断。

概率论中的基本概念

独立

对于两个离散（或连续）随机变量 X 和 Y，如果其联合概率（或联合概率密度函数）$p(x,y)$ 满足

$$p(x,y) = p(x)p(y)$$

如果两个随机变量独立，那么知道 X的取值，不会改变 Y的概率分布。

$$p(y|x) = p(y)$$

概率论中的基本概念

采样 (Sampling)

给定概率分布 $p(x)$，生成满足条件的样本. 也称抽样.

$$\boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \cdots, \boldsymbol{x}^{(n)} \sim p(\boldsymbol{x})$$

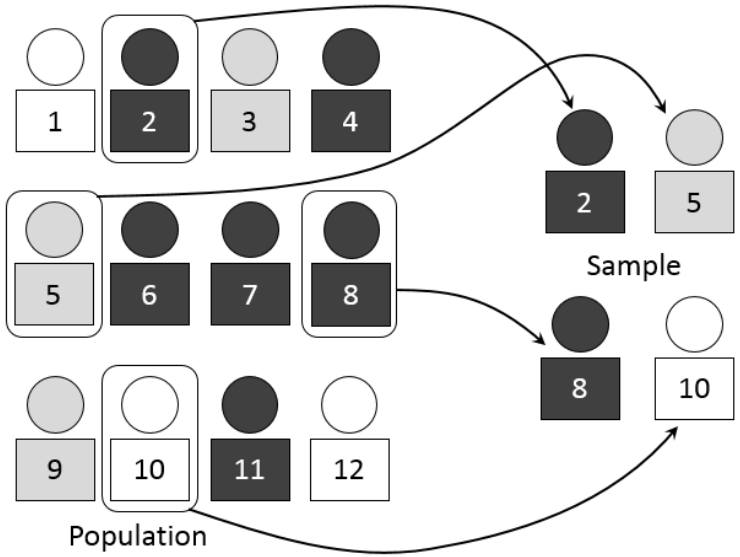

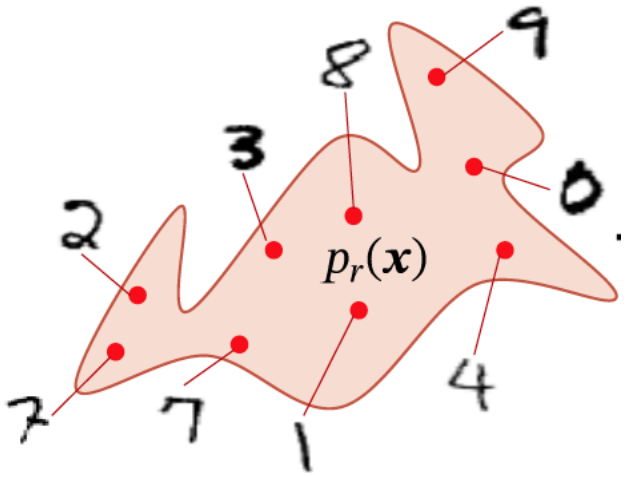

概率论中的基本概念

直接采样

计算机生成均匀分布 $U(0,1)$

$$x_{t+1} = (ax_t + c) \bmod m$$

线性同余发生器

如何生成均匀分布 $U(a,b)$?

```python
class LinearCongruentialGenerator:
    def __init__(self, seed=0):
        # LCG 的参数
        self.m = 2**31 - 1  # 模数
        self.a = 1103515245  # 乘数
        self.c = 12345  # 增量
        self.state = seed  # 初始状态

    def next(self):
        # 更新状态
        self.state = (self.a * self.state + self.c) % self.m
        # 返回 0 到 1 之间的随机数
        return self.state / self.m

# 示例用法
lcg = LinearCongruentialGenerator(seed=123)  # 可以指定种子
random_numbers = [lcg.next() for _ in range(10)]  # 生成10个随机数
print(random_numbers)
```

概率论中的基本概念

离散分布

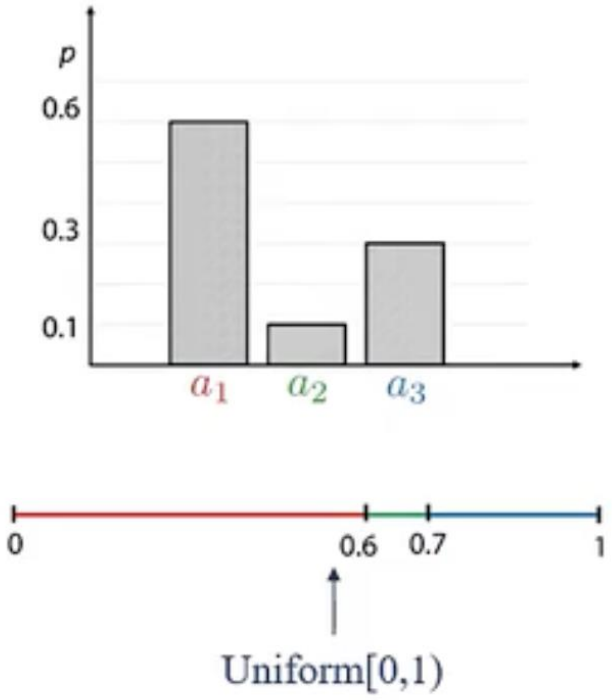

连续分布　逆变换采样

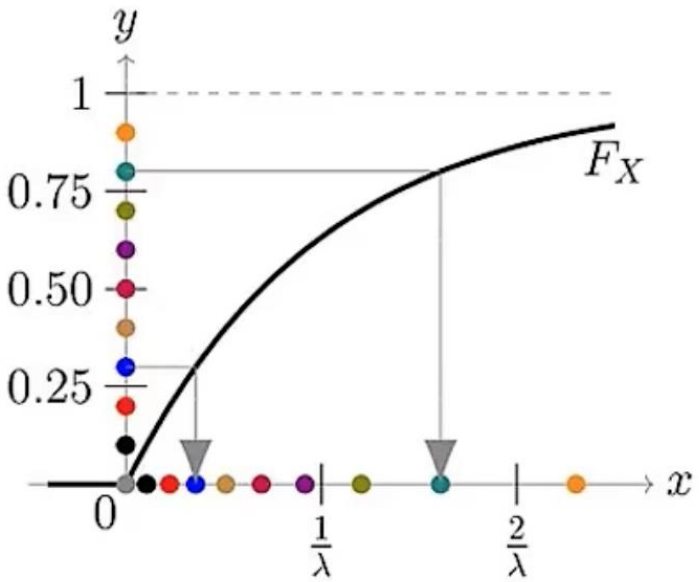

- 设随机变量 X 的分布函数为 $F(x)$, 求随机变量 $Y = F(X)$ 的分布函数.
- 若随机变量 $Y \sim U(0,1)$, 任给分布函数$F(x)$, 求随机变量 $X = F^{-1}(Y)$ 的分布函数.

概率论中的基本概念

期望 (Expectation)　　随机变量的均值

离散随机变量

$$\mathbb{E}[X] = \sum_{n=1}^{N} x_n p(x_n).$$

连续随机变量

$$\mathbb{E}[X] = \int_{\mathbb{R}} x p(x) \, \mathrm{d}x.$$

概率论中的基本概念

大数定律

形象地说:样本数量很大的时候, 样本均值和真实均值（期望）充分接近.

给定 n 个独立同分布的随机变量 $X_1, \cdots, X_n$，且具有有限数学期望

$$\mu = \mathbb{E}[X_i]$$

则对任意的 $\varepsilon > 0$，有

$$\lim_{n \to \infty} P\left\{\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \mu\right| < \varepsilon\right\} = 1.$$

线性回归

线性回归（Linear Regression）

模型：

$$f(\boldsymbol{x};\boldsymbol{w},b)=\boldsymbol{w}^{\top}\boldsymbol{x}+b,$$

增广权重向量和增广特征向量

$$\hat{\boldsymbol{x}}=\boldsymbol{x}\oplus 1\triangleq\begin{bmatrix}\boldsymbol{x}\\ 1\end{bmatrix}=\begin{bmatrix}x_1\\ \vdots\\ x_D\\ 1\end{bmatrix},$$

$$\hat{\boldsymbol{w}}=\boldsymbol{w}\oplus b\triangleq\begin{bmatrix}\boldsymbol{w}\\ b\end{bmatrix}=\begin{bmatrix}w_1\\ \vdots\\ w_D\\ b\end{bmatrix},$$

$$\longrightarrow\quad f(\boldsymbol{x};\hat{\boldsymbol{w}})=\hat{\boldsymbol{w}}^{\top}\hat{\boldsymbol{x}},$$

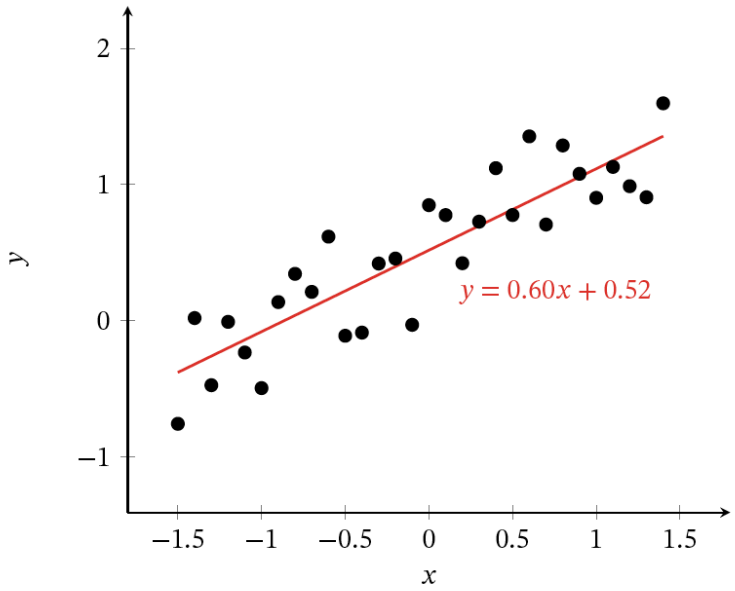

经验风险最小化

模型

$$f(\boldsymbol{x};\hat{\boldsymbol{w}}) = \hat{\boldsymbol{w}}^{\top}\hat{\boldsymbol{x}},$$

学习准则

$$\begin{aligned}\mathcal{R}(\boldsymbol{w}) &= \sum_{n=1}^{N} \mathcal{L}(y^{(n)}, f(\boldsymbol{x}^{(n)};\boldsymbol{w})) \\ &= \frac{1}{2}\sum_{n=1}^{N}\left(y^{(n)} - \boldsymbol{w}^{\top}\boldsymbol{x}^{(n)}\right)^2 \\ &= \frac{1}{2}\|\boldsymbol{y} - \boldsymbol{X}^{\top}\boldsymbol{w}\|^2,\end{aligned}$$

Why?

经验风险最小化

$$\frac{\partial}{\partial \boldsymbol{w}}\mathcal{R}(\boldsymbol{w}) = 0,$$

矩阵微积分

标量关于向量的偏导数 $\boldsymbol{x} \in \mathbb{R}^M$ $\frac{\partial y}{\partial \boldsymbol{x}} = [\frac{\partial y}{\partial x_1}, \cdots, \frac{\partial y}{\partial x_M}]^\top$

向量关于向量的偏导数 $\boldsymbol{y} = f(\boldsymbol{x}) \in \mathbb{R}^N$

$$\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_N}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_M} & \cdots & \frac{\partial y_N}{\partial x_M} \end{bmatrix} \in \mathbb{R}^{M \times N}$$

向量函数及其导数

$$\frac{\partial \boldsymbol{x}}{\partial \boldsymbol{x}} = \boldsymbol{I}, \qquad \frac{\partial \boldsymbol{A}\boldsymbol{x}}{\partial \boldsymbol{x}} = \boldsymbol{A}^\top, \qquad \frac{\partial \boldsymbol{x}^\top \boldsymbol{A}}{\partial \boldsymbol{x}} = \boldsymbol{A}.$$

经验风险最小化

链式法则 $\boldsymbol{x} \in \mathbb{R}^M, \boldsymbol{y} = g(\boldsymbol{x}) \in \mathbb{R}^K, \boldsymbol{z} = f(\boldsymbol{y}) \in \mathbb{R}^N$

$$\frac{\partial \boldsymbol{z}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{y}} \quad \in \mathbb{R}^{M \times N}.$$

$$\frac{\partial}{\partial \boldsymbol{w}} \mathcal{R}(\boldsymbol{w}) = 0, \qquad \mathcal{R}(\boldsymbol{w}) = \frac{1}{2} \|\boldsymbol{y} - \boldsymbol{X}^\top \boldsymbol{w}\|^2,$$

则有

$$\begin{aligned} \frac{\partial \mathcal{R}(\boldsymbol{w})}{\partial \boldsymbol{w}} &= \frac{1}{2} \frac{\partial \|\boldsymbol{y} - \boldsymbol{X}^\top \boldsymbol{w}\|^2}{\partial \boldsymbol{w}} \\ &= -\boldsymbol{X}(\boldsymbol{y} - \boldsymbol{X}^\top \boldsymbol{w}), \end{aligned}$$

$$\boldsymbol{w}^* = (\boldsymbol{X}\boldsymbol{X}^\top)^{-1} \boldsymbol{X} \boldsymbol{y}$$

结构风险最小化

当特征之间存在共线性时， $\boldsymbol{X}\boldsymbol{X}^T$ 不可逆

结构风险最小化准则

$$\mathcal{R}(\boldsymbol{w}) = \frac{1}{2}||\boldsymbol{y} - \boldsymbol{X}^{\top}\boldsymbol{w}||^2 + \frac{1}{2}\lambda||\boldsymbol{w}||^2,$$

令其最小化, 得到

$$\boldsymbol{w}^* = (\boldsymbol{X}\boldsymbol{X}^{\top} + \lambda I)^{-1}\boldsymbol{X}\boldsymbol{y},$$

岭回归

机器学习中的两种建模思路

函数关系建模

寻找一个未知函数 f, 使 $y \approx f(\boldsymbol{x})$

方法：通过最小化误差（如平方误差）来学习函数

最小二乘回归

支持向量机

“输入经过一个函数变成输出”。

条件概率建模

学习条件概率分布 $p(y \mid \boldsymbol{x})$

假设某种概率模型，通过极大似然估计参数

Logistic 回归

贝叶斯网络

“给定输入时，输出出现的概率是多少”

从概率角度来看线性回归

假设标签 y 为一个随机变量，其服从以均值为$f(x;w) = w^T x$，方差为σ^2的高斯分布

$$y = f(\boldsymbol{x};\boldsymbol{w}) + \epsilon,$$

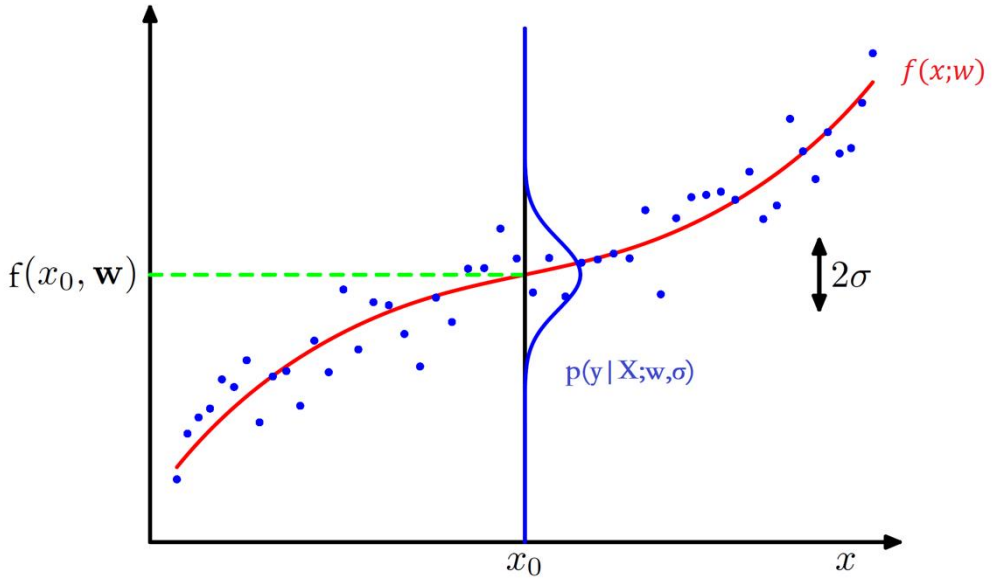

$$p(y|\boldsymbol{x};\boldsymbol{w},\sigma) = \mathcal{N}(y;\boldsymbol{w}^\top\boldsymbol{x},\sigma^2)$$
$$= \frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(y-\boldsymbol{w}^\top\boldsymbol{x})^2}{2\sigma^2}\right).$$

似然函数

似然函数是关于统计模型 $p(X;w)$ 的参数 w 的函数

概率 $p(X;w)$ 是描述固定参数 w 时随机变量 X 的分布情况

“在参数 w已知时，数据 X出现的概率是多少？”

似然 $p(X;w)$ 则是描述已知随机变量 X 时不同的参数 w 对其分布的影响

“在数据 X已观测时，哪个参数 w更可能产生这些数据？”

概率：已知硬币正面概率 $w = 0.7$，计算出现 7 次正面的概率。

似然：已经观察到 10 次里出现 7 次正面，哪个 w更可能产生这个结果？

线性回归中的似然函数

参数 w 在训练集 D 上的似然函数为

$$
\begin{aligned}
p(\boldsymbol{y}|\boldsymbol{X};\boldsymbol{w},\sigma) &= \prod_{n=1}^{N} p(y^{(n)}|\boldsymbol{x}^{(n)};\boldsymbol{w},\sigma) \\
&= \prod_{n=1}^{N} \mathcal{N}(y^{(n)};\boldsymbol{w}^{\top}\boldsymbol{x}^{(n)},\sigma^2),
\end{aligned}
$$

$\boldsymbol{y} = [y^{(1)},\cdots,y^{(N)}]^{\top}$ 为所有样本标签组成的向量

$\boldsymbol{X} = [\boldsymbol{x}^{(1)},\cdots,\boldsymbol{x}^{(N)}]$ 为所有样本特征向量组成的矩阵

最大似然估计

最大似然估计（Maximum Likelihood Estimate，MLE）

是指找到一组参数 w 使得似然函数 $p(\boldsymbol{y}|\boldsymbol{X};\boldsymbol{w},\sigma)$ 最大

$$\log p(\boldsymbol{y}|\boldsymbol{X};\boldsymbol{w},\sigma) = \sum_{n=1}^{N} \log \mathcal{N}(y^{(n)};\boldsymbol{w}^\top \boldsymbol{x}^{(n)},\sigma^2).$$

$$p(y|\boldsymbol{x};\boldsymbol{w},\sigma) = \mathcal{N}(y;\boldsymbol{w}^\top \boldsymbol{x},\sigma^2) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(y-\boldsymbol{w}^\top \boldsymbol{x})^2}{2\sigma^2}\right).$$

$$\frac{\partial \log p(\boldsymbol{y}|\boldsymbol{X};\boldsymbol{w},\sigma)}{\partial \boldsymbol{w}} = 0 \quad \Longrightarrow \quad \boldsymbol{w}^{ML} = (\boldsymbol{X}\boldsymbol{X}^\top)^{-1}\boldsymbol{X}\boldsymbol{y}.$$

最大似然估计的解和最小二乘法的解相同.

贝叶斯的视角

贝叶斯学习

将参数 w 也看作随机变量

目标：给定一组观测数据 X，求参数 w 的分布 $p(w|X)$

$p(w|X)$ 也称为后验分布

贝叶斯公式

两个条件概率 $p(y|x)$ 和 $p(x|y)$ 之间的关系

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

后验、似然、先验

$$p(w|x) \propto p(x|w)p(w)$$

后验	似然	先验
posterior	likelihood	prior

贝叶斯估计

采用贝叶斯估计的线性回归也称为贝叶斯线性回归

设随机变量 w 服从先验分布 $p(\boldsymbol{w};\nu) = \mathcal{N}(\boldsymbol{w};\boldsymbol{0},\nu^2 I),$

$$p(\boldsymbol{w}|\boldsymbol{X},\boldsymbol{y};\nu,\sigma) = \frac{p(\boldsymbol{w},\boldsymbol{y}|\boldsymbol{X};\nu,\sigma)}{\sum_{\boldsymbol{w}} p(\boldsymbol{w},\boldsymbol{y}|\boldsymbol{X};\nu,\sigma)}$$
$$\propto p(\boldsymbol{y}|\boldsymbol{X},\boldsymbol{w};\sigma)p(\boldsymbol{w};\nu),$$

后验 posterior　　似然 likelihood　　先验 prior

$$\log p(\boldsymbol{w}|\boldsymbol{X},\boldsymbol{y};\nu,\sigma) \propto \log p(\boldsymbol{y}|\boldsymbol{X},\boldsymbol{w};\sigma) + \log p(\boldsymbol{w};\nu)$$
$$\propto -\frac{1}{2\sigma^2}\sum_{n=1}^{N}\left(y^{(n)} - \boldsymbol{w}^\top \boldsymbol{x}^{(n)}\right)^2 - \frac{1}{2\nu^2}\boldsymbol{w}^\top\boldsymbol{w},$$
$$= -\frac{1}{2\sigma^2}||\boldsymbol{y} - \boldsymbol{X}^\top\boldsymbol{w}||^2 - \frac{1}{2\nu^2}\boldsymbol{w}^\top\boldsymbol{w}.$$

$$p(y^* \mid \boldsymbol{x}^*, \boldsymbol{X}, \boldsymbol{y}) = \int p(y^* \mid \boldsymbol{x}^*, \boldsymbol{w})p(\boldsymbol{w} \mid \boldsymbol{X}, \boldsymbol{y})d\boldsymbol{w}.$$

最大后验估计

贝叶斯估计是一种参数的区间估计，即参数在一个区间上的分布

如果我们希望得到一个最优的参数值（即点估计），可以使用最大后验估计

$$\boldsymbol{w}^{MAP} = \arg\max_{\boldsymbol{w}} p(\boldsymbol{y}|\boldsymbol{X}, \boldsymbol{w}; \sigma) p(\boldsymbol{w}; \nu),$$

求解

$$\boldsymbol{w}^* = (\boldsymbol{X}\boldsymbol{X}^\top + \lambda I)^{-1}\boldsymbol{X}\boldsymbol{y}, \qquad \lambda = \sigma^2/\nu^2$$

线性回归总结

	无先验	引入先验
平方误差	经验风险 最小化	结构风险 最小化
概率	最大似然估计	最大后验估计

$$\boldsymbol{w}^{ML} = (\boldsymbol{X}\boldsymbol{X}^\top)^{-1}\boldsymbol{X}\boldsymbol{y}$$

$$\boldsymbol{w}^{*} = (\boldsymbol{X}\boldsymbol{X}^\top + \lambda I)^{-1}\boldsymbol{X}\boldsymbol{y}$$

谢谢！