

循环神经网络

《神经网络与深度学习》第6讲

提纲

- 循环神经网络
- 应用到机器学习
- 参数学习与长程依赖问题
- GRU与LSTM
- 循环神经网络的应用
- 扩展到图结构


前馈网络

层与层之间存在**单向连接**，每层的节点之间**无连接**


有向无环图

输入和输出的维数都是固定的，不能任意改变

全连接前馈网络无法处理变长的序列数据



(a) 全连接层




(b) 卷积层

序列处理


one to one




one to many




many to one



many to many




many to many



前馈网络


假设每次输入都是独立的，也就是说每次网络的输出只依赖于当前的输入



有限状态自动机 (Finite Automata)

$x \in \{0,1\}$


$y \in \{S_0, S_1, S_2\}$



如何用前馈神经网络去模拟一个有限状态自动机？

图灵机

一种抽象数学模型，可以用来模拟任何可计算问题




时滞微分方程

微分方程


$$\frac{dx(t)}{dt} = -\alpha x(t)$$

时滞微分方程

$$\frac{dx(t)}{dt} = -\alpha x(t) + \beta x(t - \tau)$$



可计算问题



如何给网络增加记忆能力？

如何给网络增加记忆能力？


延时神经网络（Time Delay Neural Network）

建立一个额外的延时单元，用来存储网络的历史信息（可以包括输入、输出、隐状态等）

$$\mathbf{h}_t^{(l)} = f\left(\mathbf{h}_t^{(l-1)}, \mathbf{h}_{t-1}^{(l-1)}, \dots, \mathbf{h}_{t-K}^{(l-1)}\right),$$

这样，前馈网络就具有了短期记忆的能力

与CNN的关系？



如何给网络增加记忆能力？

自回归模型(Autoregressive Model)

一类时间序列模型，用变量 y_t 的历史信息来预测自己

$$y_t = w_0 + \sum_{k=1}^K w_k y_{t-k} + \epsilon_t,$$


$\epsilon_t \sim N(0, \sigma^2)$ 为第 t 个时刻的噪声

有外部输入的非线性自回归模型 (1985)

$$y_t = f(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-K_x}, y_{t-1}, y_{t-2}, \dots, y_{t-K_y}),$$

其中 $f(\cdot)$ 表示非线性函数，可以是一个前馈网络， K_x 和 K_y 为超参数

非线性自回归模型




https://www.researchgate.net/publication/234052442_Braking_torque_control_using_reccurent_neural_networks

循环神经网络（Recurrent Neural Network, RNN）

循环神经网络通过使用带自反馈的神经元，能够处理任意长度的时序数据

$$h_t = f(h_{t-1}, x_t)$$

活性值状态





思考：循环神经网络和时延神经网络、自回归模型在记忆方式上的差异？

循环神经网络比前馈神经网络更加符合生物神经网络的结构

循环神经网络已经被广泛应用于语音识别、语言模型以及自然语言生成等任务上

按时间展开



$$h_t = f(Uh_{t-1} + Wx_t + b)$$

简单循环网络（ Simple Recurrent Network , SRN ）

状态更新：

$$\mathbf{h}_t = f(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b})$$

一个完全连接的循环网络是任何非线性动力系统的近似器

定理 6.1 – 循环神经网络的通用近似定理 [Haykin, 2009]： 如果一个完全连接的循环神经网络有足够数量的 sigmoid 型隐藏神经元，它可以以任意的准确率去近似任何一个非线性动力系统

$$\mathbf{s}_t = g(\mathbf{s}_{t-1}, \mathbf{x}_t), \quad (6.10)$$

$$\mathbf{y}_t = o(\mathbf{s}_t), \quad (6.11)$$

其中 $\mathbf{s}_t$ 为每个时刻的隐状态， $\mathbf{x}_t$ 是外部输入， $g(\cdot)$ 是可测的状态转换函数， $o(\cdot)$ 是连续输出函数，并且对状态空间的紧致性没有限制。

图灵完备

图灵完备（Turing Completeness）是指一种数据操作规则

比如一种计算机编程语言，可以实现图灵机的所有功能，解决所有的可计算问题

定理 6.2 – 图灵完备 [Siegelmann et al., 1991]: 所有的图灵机都可以被一个由使用 Sigmoid 型激活函数的神经元构成的全连接循环网络来进行模拟.

一个完全连接的循环神经网络可以近似解决所有的可计算问题

循环神经网络

作用

输入-输出映射


机器学习模型

存储器


联想记忆模型

应用到机器学习

序列到类别



(a) 正常模式





(b) 按时间进行平均采样模式

应用？


序列到类别

情感分类



RNN应用到机器学习


同步的序列到序列模式



$$\hat{y}_t = g(\mathbf{h}_t), \quad \forall t \in [1, T].$$

同步的序列到序列模式

中文分词




同步的序列到序列模式

信息抽取(Information Extraction, IE)


从无结构的文本中抽取结构化的信息，形成知识

小米创始人雷军表示，该公司2024年营收达到3659亿元人民币，较2023年的2710亿元人民币增长了35%.




同步的序列到序列模式


Connectionist Temporal Classification (CTC) [Alex Graves, ICML'06][Alex Graves, ICML'14][Haşim Sak, Interspeech'15][Jie Li, Interspeech'15][Andrew Senior, ASRU'15]



语音识别




异步的序列到序列模式



异步的序列到序列模式

机器翻译



RNN应用到机器学习

序列到类别

情感分类

同步的序列到序列模式

中文分词

异步的序列到序列模式

机器翻译

参数学习

机器学习

给定一个训练样本 $(\mathbf{x}, \mathbf{y})$ ，其中

$\mathbf{x} = (x_1, \dots, x_T)$ 为长度是 T 的输入序列

$\mathbf{y} = (y_1, \dots, y_T)$ 为长度是 T 的输出序列




图 6.4 同步的序列到序列模式

时刻 t 的瞬时损失函数


$$\mathcal{L}_t = \mathcal{L}(y_t, g(\mathbf{h}_t)),$$

总损失函数

$$\mathcal{L} = \sum_{t=1}^T \mathcal{L}_t.$$

参数学习

RNN: Computational Graph: Many to Many



计算梯度

随时间反向传播算法 (BackPropagation Through Time, BPTT)

$$\mathbf{z}_k = \mathbf{U}\mathbf{h}_{k-1} + \mathbf{W}\mathbf{x}_k + \mathbf{b}$$


$$\mathbf{h}_k = f(\mathbf{z}_k)$$

$$1 \leq k \leq t$$

$$\frac{\partial \mathcal{L}_t}{\partial u_{ij}} = \sum_{k=1}^t \frac{\partial^+ \mathbf{z}_k}{\partial u_{ij}} \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_k},$$

$$\frac{\partial^+ \mathbf{z}_k}{\partial u_{ij}} = [0, \dots, [\mathbf{h}_{k-1}]_j, \dots, 0]$$

$$\triangleq \mathbb{I}_i([\mathbf{h}_{k-1}]_j),$$



$$\begin{aligned} \delta_{t,k} &= \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_k} \\ &= \frac{\partial \mathbf{h}_k}{\partial \mathbf{z}_k} \frac{\partial \mathbf{z}_{k+1}}{\partial \mathbf{h}_k} \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_{k+1}} \\ &= \text{diag}(f'(\mathbf{z}_k)) \mathbf{U}^\top \delta_{t,k+1}. \end{aligned}$$

$$\begin{aligned} \frac{\partial \mathcal{L}_t}{\partial \mathbf{U}} &= \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^\top \\ \frac{\partial \mathcal{L}}{\partial \mathbf{U}} &= \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^\top. \end{aligned}$$

计算梯度

随时间反向传播算法 (BackPropagation Through Time, BPTT)

$$\mathbf{z}_k = \mathbf{U}\mathbf{h}_{k-1} + \mathbf{W}\mathbf{x}_k + \mathbf{b}$$


$$\mathbf{h}_k = f(\mathbf{z}_k)$$

$$1 \leq k \leq t$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{U}} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^\top$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{x}_k^\top$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k}$$



$$\begin{aligned} \delta_{t,k} &= \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_k} \\ &= \frac{\partial \mathbf{h}_k}{\partial \mathbf{z}_k} \frac{\partial \mathbf{z}_{k+1}}{\partial \mathbf{h}_k} \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_{k+1}} \\ &= \text{diag}(f'(\mathbf{z}_k)) \mathbf{U}^\top \delta_{t,k+1} \end{aligned}$$

梯度消失/爆炸

梯度

$$\frac{\partial \mathcal{L}}{\partial \mathbf{U}} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^\top.$$

$$\delta_{t,k} = \prod_{\tau=k}^{t-1} \left(\text{diag}(f'(\mathbf{z}_\tau)) \mathbf{U}^\top \right) \delta_{t,t}.$$

如果定义 $\gamma \cong \|\text{diag}(f'(\mathbf{z}_\tau)) \mathbf{U}^\top\|$

$$\delta_{t,k} \cong \gamma^{t-k} \delta_{t,t}.$$

由于梯度爆炸或消失问题，实际上只能学习到短周期的依赖关系。
这就是所谓的长程依赖问题

长程依赖问题

循环神经网络在时间维度上非常深

梯度消失或梯度爆炸

如何改进

梯度爆炸问题

权重衰减

梯度截断

梯度消失问题

改进模型

长程依赖问题

简单的改进方法

循环边改为线性依赖关系

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t; \theta),$$

增加非线性

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta),$$

残差网络?

梯度爆炸问题

记忆容量

$$\mathbf{z}_k = \mathbf{U}\mathbf{h}_{k-1} + \mathbf{W}\mathbf{x}_k + \mathbf{b}$$

$$\mathbf{h}_k = f(\mathbf{z}_k)$$

$$\begin{aligned}\delta_{t,k} &= \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_k} \\ &= \frac{\partial \mathbf{h}_k}{\partial \mathbf{z}_k} \frac{\partial \mathbf{z}_{k+1}}{\partial \mathbf{h}_k} \frac{\partial \mathcal{L}_t}{\partial \mathbf{z}_{k+1}} \\ &= \text{diag}(f'(\mathbf{z}_k)) \mathbf{U}^\top \delta_{t,k+1}.\end{aligned}$$

$$\delta_{t,k} = \prod_{\tau=k}^{t-1} \left(\text{diag}(f'(\mathbf{z}_\tau)) \mathbf{U}^\top \right) \delta_{t,t}.$$

门控机制

长程依赖问题

门控机制 (gate)

控制信息的累积速度，包括有选择地加入新的信息，并有选择地遗忘之前累积的信息

基于门控的循环神经网络 (Gated RNN)

门控循环单元 (GRU)

长短期记忆网络 (LSTM)

门控循环单元 Gated Recurrent Unit, GRU

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta)$$



$$\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta),$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h \mathbf{h}_{t-1} + \mathbf{b}_h)$$


$\mathbf{z}_t \in [0, 1]^D$ 为更新门

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z).$$

$\mathbf{r}_t \in [0, 1]^D$ 为重置门

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r), \quad \tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{t-1}) + \mathbf{b}_h)$$

门控循环单元 Gated Recurrent Unit, GRU




$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r),$$

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z),$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}(\mathbf{r}_t \odot \mathbf{h}_{t-1}))$$

$$\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot \tilde{\mathbf{h}}_t,$$

长短期记忆神经网络 (Long Short-Term Memory, LSTM)



$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c).$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t,$$

$$h_t = o_t \odot \tanh(c_t),$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i), \quad \text{输入门}$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f), \quad \text{遗忘门}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o), \quad \text{输出门}$$

LSTM 的各种变体

没有遗忘门

$$\mathbf{c}_t = \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t.$$

耦合输入门和遗忘

$$\mathbf{c}_t = (1 - \mathbf{i}_t) \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t.$$

peephole连接

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \mathbf{x}_t + \mathbf{U}_i \mathbf{h}_{t-1} + \mathbf{V}_i \mathbf{c}_{t-1} + \mathbf{b}_i),$$

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{V}_f \mathbf{c}_{t-1} + \mathbf{b}_f),$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \mathbf{x}_t + \mathbf{U}_o \mathbf{h}_{t-1} + \mathbf{V}_o \mathbf{c}_t + \mathbf{b}_o),$$

LSTM

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}_c \mathbf{h}_{t-1} + \mathbf{b}_c).$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t,$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t),$$

长程依赖问题

循环神经网络在时间维度上非常深

梯度消失

门控机制 (gate)


控制信息的累积速度，包括有选择地加入新的信息，并有选择地遗忘之前累积的信息

基于门控的循环神经网络 (Gated RNN)


门控循环单元 (GRU)

长短期记忆网络 (LSTM)

堆叠循环神经网络



双向循环神经网络



循环神经网络小结

优点

引入（短期）记忆

图灵完备

缺点

长程依赖问题

记忆容量问题

并行能力

语言模型

自然语言理解 → 一个句子的可能性/合理性

！在报那猫告做只 🤔

那只猫在作报告！ 😓

那个人在作报告！ 😊

一切都是概率！


$$P(x_1, x_2, \dots, x_T)$$

$$= \prod_i P(x_i | x_{i-1}, \dots, x_1)$$

$$\approx \prod_i P(x_i | x_{i-1}, \dots, x_{i-n+1})$$



语言模型



我爱故乡的槐花香，
飘过小巷时总牵着童年的影子。

生成Linux内核代码

```
#include <linux/module.h>
#include <linux/kernel.h>

MODULE_LICENSE("GPL");
MODULE_AUTHOR("Your Name");
MODULE_DESCRIPTION("A Simple Linux Kernel Module");
MODULE_VERSION("0.1");

static int __init simple_module_init(void) {
    printk(KERN_INFO "Simple Module Loaded: Hello, World!\n");
    return 0; // 返回0表示模块加载成功
}

static void __exit simple_module_exit(void) {
    printk(KERN_INFO "Simple Module Unloaded: Goodbye, World!\n");
}

module_init(simple_module_init);
module_exit(simple_module_exit);
```

作词机

RNN在“学习”过汪峰全部作品后自动生成的歌词

我在这里中的夜里
就像一场是一种生命的意叶
就像我的生活变得在我一样
可我们这是一个知道
我只是一天你会怎吗
可我们这是我们是不要为你
我们想这有一种生活的时候

在那无尽的夜空下，
星光闪烁如你的眼，
我追逐着梦想的轨迹，
心中的火焰永不灭。

作诗


白鹭窥鱼立， Egrets stood, peeping fishes. 青山照水开。 Water was still, reflecting mountains. 夜来风不动， The wind went down by nightfall, 明月见楼台。 as the moon came up by the tower.	满怀风月一枝春， Budding branches are full of romance. 未见梅花亦可人。 Plum blossoms are invisible but adorable. 不为东风无此客， With the east wind comes Spring. 世间何处是前身。 Where on earth do I come from?
--	--

月照山川静夜寒，
风吹松影似人还。
一帘幽梦随云去，
千古情怀共此间。


基于序列到序列的机器翻译

一个RNN用来编码

另一个RNN用来解码



看图说话



A group of people shopping at an outdoor market.

There are many vegetables at the fruit stand.

看图说话






Figure 5. A selection of evaluation results, grouped by human rating.

写字

把一个字母的书写轨迹看作是一连串的点。一个字母的“写法”其实是每一个点相对于前一个点的偏移量，记为(offset x, offset y)。再增加一维取值为0或1来记录是否应该“提笔”。



对话系统




扩展到图结构




树结构

程序语言的句法结构




树结构

自然语言的句法结构



递归神经网络 Recursive Neural Network

递归神经网络实在一个有向无循环图上共享一个组合函数




$$\mathbf{h}_i = f(\mathbf{h}_{\pi_i})$$

$$\begin{aligned}\mathbf{h}_1 &= f\left(W \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix} + \mathbf{b}\right), \\ \mathbf{h}_2 &= f\left(W \begin{bmatrix} \mathbf{x}_3 \\ \mathbf{x}_4 \end{bmatrix} + \mathbf{b}\right), \\ \mathbf{h}_3 &= f\left(W \begin{bmatrix} \mathbf{h}_1 \\ \mathbf{h}_2 \end{bmatrix} + \mathbf{b}\right),\end{aligned}$$

递归神经网络 Recursive Neural Network

退化为循环神经网络




$$\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t),$$

递归神经网络 Recursive Neural Network

给定一个语法树，

$p_2 \rightarrow ap_1$,

$p_1 \rightarrow bc$.




$$p_1 = f\left(W \begin{bmatrix} b \\ c \end{bmatrix}\right),$$

$$p_2 = f\left(W \begin{bmatrix} a \\ p_1 \end{bmatrix}\right).$$


图网络

在实际应用中，很多数据是图结构的，比如知识图谱、社交网络、分子网络等。而前馈网络和循环网络很难处理图结构的数据。




图数据

(a) Molecule




(b) Mass-Spring System




(c) n -body System




(d) Rigid Body System




(e) Sentence and Parse Tree




(f) Image and Fully-Connected Scene Graph




图网络




图网络



(a) Edge update



(b) Node update



(c) Global update

图网络

对于一个任意的图结构 $G(V,E)$

更新函数

$$\mathbf{m}_t^{(v)} = \sum_{u \in \mathcal{N}(v)} f(\mathbf{h}_{t-1}^{(v)}, \mathbf{h}_{t-1}^{(u)}, \mathbf{e}^{(u,v)}),$$

$$\mathbf{h}_t^{(v)} = g(\mathbf{h}_{t-1}^{(v)}, \mathbf{m}_t^{(v)}),$$

读出函数

$$\mathbf{o}_t = g(\{\mathbf{h}_T^{(v)} | v \in \mathcal{V}\}).$$

谢谢！